Estatística e Probabilidade

Samir A. M. Martins[1]

[1]Universidade Federal de São João del-Rei
Departamento de Engenharia Elétrica
São João del-Rei, MG – Brasil

Graduação em Engenharia Elétrica

Estatística

Por que descrever um conjunto de dados?

- Em aplicações de Engenharia, quase sempre começamos com uma lista de medições: temperaturas, correntes, tempos de resposta, defeitos por lote.
- Uma tabela crua contém informação, mas nem sempre mostra o comportamento geral do sistema.
- A estatística descritiva transforma muitos valores em poucos resumos úteis.
- Esses resumos ajudam a responder perguntas como:
  - qual é o valor típico?
  - quanto os dados variam?
  - há valores extremos?
  - duas variáveis parecem caminhar juntas?

Por que descrever um conjunto de dados?

Exemplo inicial: tempos de resposta de um sensor, em milissegundos:

$$9{,}8,\ 10{,}1,\ 10{,}0,\ 9{,}9,\ 10{,}2,\ 10{,}1,\ 9{,}7,\ 15{,}4$$

- a maior parte dos valores está próxima de 10 ms;
- existe um valor claramente destoante: 15,4 ms;
- um resumo adequado deve mostrar o centro e também a variabilidade.

Tendência central

Ideia intuitiva: medir o valor "típico" do conjunto.

Principais medidas:

- **Média**: soma dos valores dividida pelo número de observações.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

- **Mediana**: valor central após ordenar os dados.
- **Moda**: valor mais frequente.

Interpretação:

- a média usa toda a informação numérica;
- a mediana é mais robusta a valores extremos;
- a moda é útil quando há repetições relevantes ou dados categóricos.

Quando a média pode ser enganosa?

Compare dois cenários de consumo diário de energia de um pequeno laboratório:

Consumo (kWH)	Média (kWH)	Mediana (kWH)
$12, 12, 13, 13, 14$	12,8	13
$12, 12, 13, 13, 40$	18	13

- No segundo caso, um único pico de consumo desloca a média.
- A mediana permanece em 13, representando melhor o comportamento usual.
- Em dados com *outliers*, média e mediana devem ser analisadas em conjunto.

Dispersão

Ideia intuitiva: quantificar o quão espalhados os dados estão.

Medidas importantes:

- **Amplitude**: máximo menos mínimo.
- **Variância**: média dos desvios quadráticos em relação à média.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

- **Desvio padrão**: raiz quadrada da variância.
- **Intervalo interquartil (IIQ)**: $Q_3 - Q_1$, útil para capturar a faixa central.

Interpretação: valores maiores de dispersão indicam menor regularidade do processo.

Mesma média, dispersões diferentes

Considere dois conjuntos com mesma média:

Medida	Sensor A	Sensor B
Dados	$9, 10, 10, 10, 11$	$6, 8, 10, 12, 14$
Média	10	10
Amplitude	2	8
Leitura	Estável	Muito mais disperso

Ter a mesma média não implica ter o mesmo comportamento operacional.

Python: estatística descritiva

```
import numpy as np
import statistics as st

tempos = [9.8, 10.1, 10.0, 9.9, 10.2, 10.1, 9.7, 15.4]
media = st.mean(tempos)
mediana = st.median(tempos)
desvio = st.stdev(tempos)
q1, q2, q3 = np.percentile(sorted(tempos), [25, 50, 75])
print(media, mediana, desvio, q1, q3, q3 - q1)
```

- A média sobe por causa do 15,4, embora a maioria dos tempos esteja perto de 10.
- A mediana continua próxima do valor central esperado.
- O desvio padrão aumenta, sinalizando maior instabilidade.
- Em um relatório técnico, seria razoável mencionar o valor extremo e investigar sua causa.

Erro comum: resumir informações pela média e ignorar a dispersão.

O efeito de um valor extremo

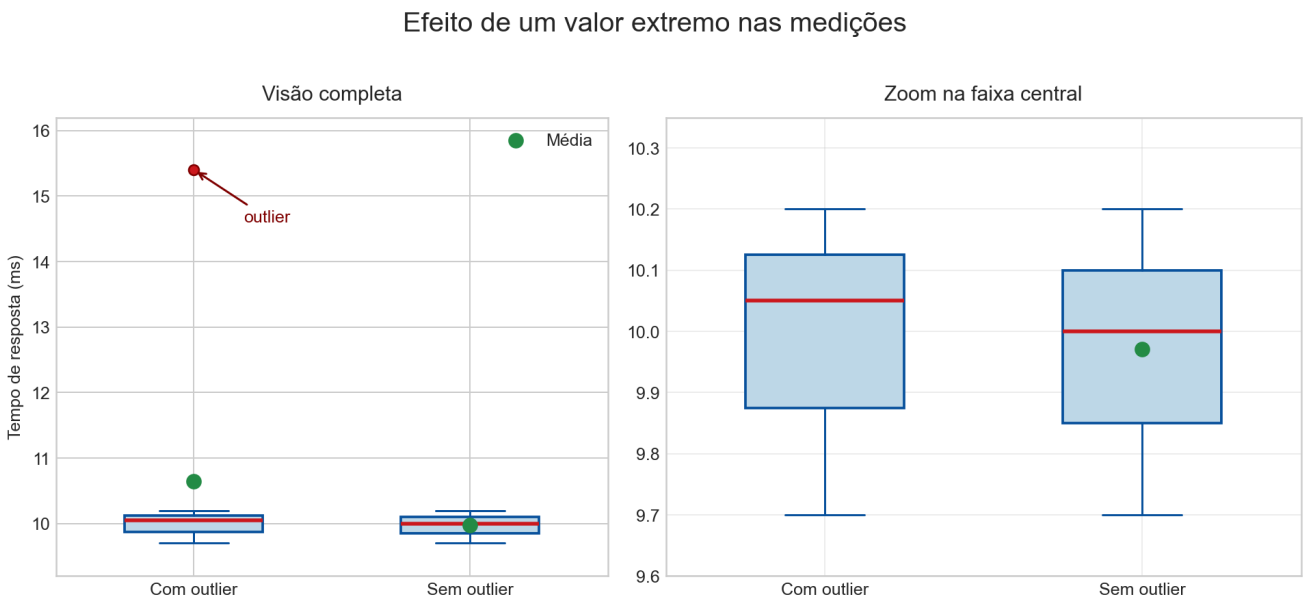

- O boxplot evidencia como um único ponto extremo altera a leitura visual do conjunto.
- Esse tipo de figura complementa média, mediana e desvio padrão.

Como ler um boxplot

- A linha dentro da caixa é a **mediana**.
- A base e o topo da caixa são Q_1 e Q_3, os quartis que delimitam os 50% centrais dos dados.
- A altura da caixa é o **intervalo interquartil**: $IIQ = Q_3 - Q_1$.
- Os "bigodes" mostram a extensão dos valores não extremos; pontos isolados sugerem possíveis *outliers*.

Na convenção mais comum, os bigodes vão até:

$$\text{limite inferior} = Q_1 - 1{,}5 \cdot IIQ \qquad \text{e} \qquad \text{limite superior} = Q_3 + 1{,}5 \cdot IIQ$$

Interpretação: caixa baixa e compacta indica concentração; caixa alta ou assimétrica indica mais dispersão ou desequilíbrio entre as metades do conjunto.

Correlação: ideia intuitiva

Pergunta central: quando uma variável aumenta, a outra tende a aumentar, diminuir ou não seguir padrão?

- Correlação mede associação, em especial associação linear entre desvios em torno das médias.
- Correlação positiva: duas variáveis tendem a crescer juntas.
- Correlação negativa: uma cresce enquanto a outra tende a cair.
- Correlação próxima de zero: não há tendência linear clara.

Coeficiente de correlação

O coeficiente de correlação de Pearson é dado por:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

- $r \in [-1, 1]$.
- Ele normaliza a covariância, isto é, compara como x e y variam juntos em unidades padronizadas.
- Valores próximos de 1: forte associação linear positiva.
- Valores próximos de -1: forte associação linear negativa.
- Valores próximos de 0: associação linear fraca ou inexistente.

Atenção: o valor de r não informa, sozinho, inclinação, mecanismo físico ou robustez da relação.

Três cenários de correlação

Cenário	Exemplo interpretativo
Positiva	maior corrente em carga resistiva, maior aquecimento observado
Negativa	maior distância de um transmissor *wireless*, menor intensidade de sinal
Próxima de zero	último dígito da matrícula do aluno *vs* nota na disciplina

Três cenários de correlação

Em todos os casos, a pergunta correta é: **o padrão é linear, estável e plausível?**

- Um valor alto de r sugere associação linear, não uma lei física definitiva.
- O gráfico de dispersão mostra se a relação parece reta, curva ou apenas ruído.
- Relações não lineares podem ter correlação baixa mesmo quando existe dependência forte.
- Com poucas observações, qualquer conclusão deve ser mais cautelosa.

Correlação positiva

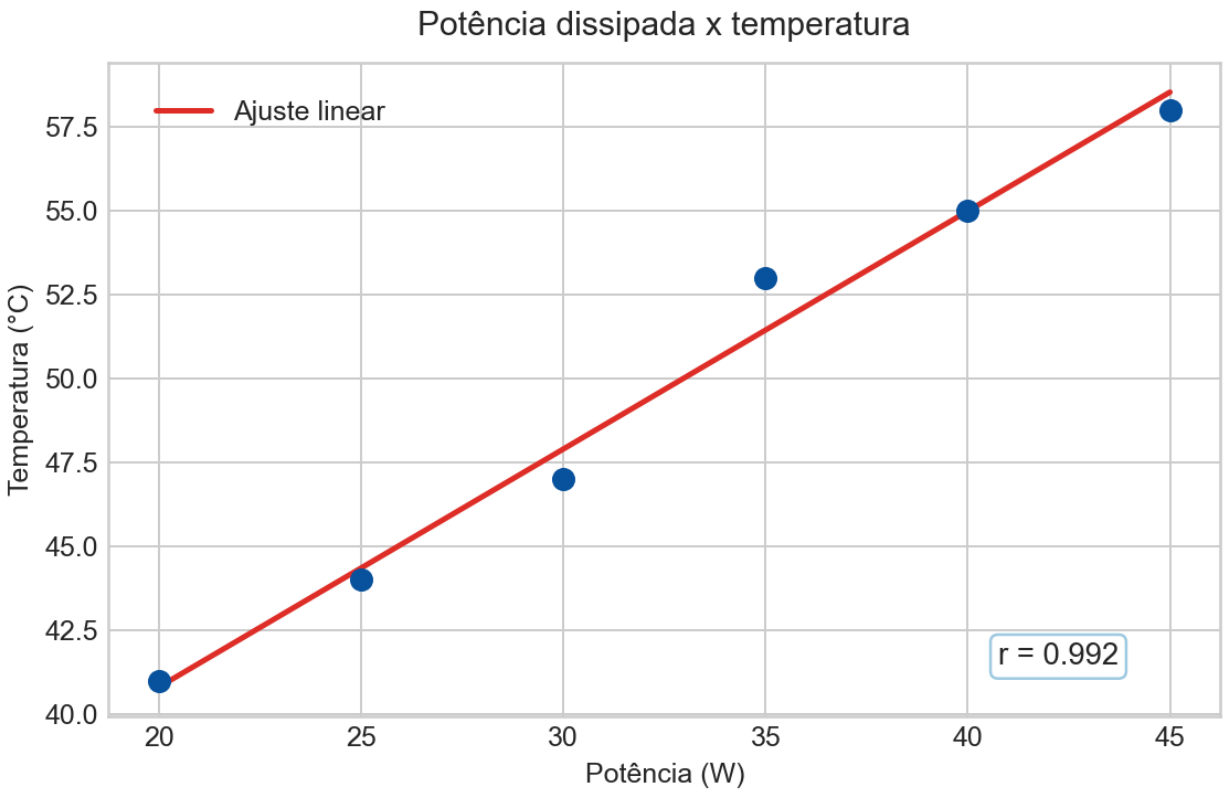

- A reta ajustada ajuda a ver que os desvios em torno da tendência são pequenos.
- Neste caso, o coeficiente resume bem o padrão porque a geometria do gráfico é aproximadamente linear.

Alertas sobre correlação

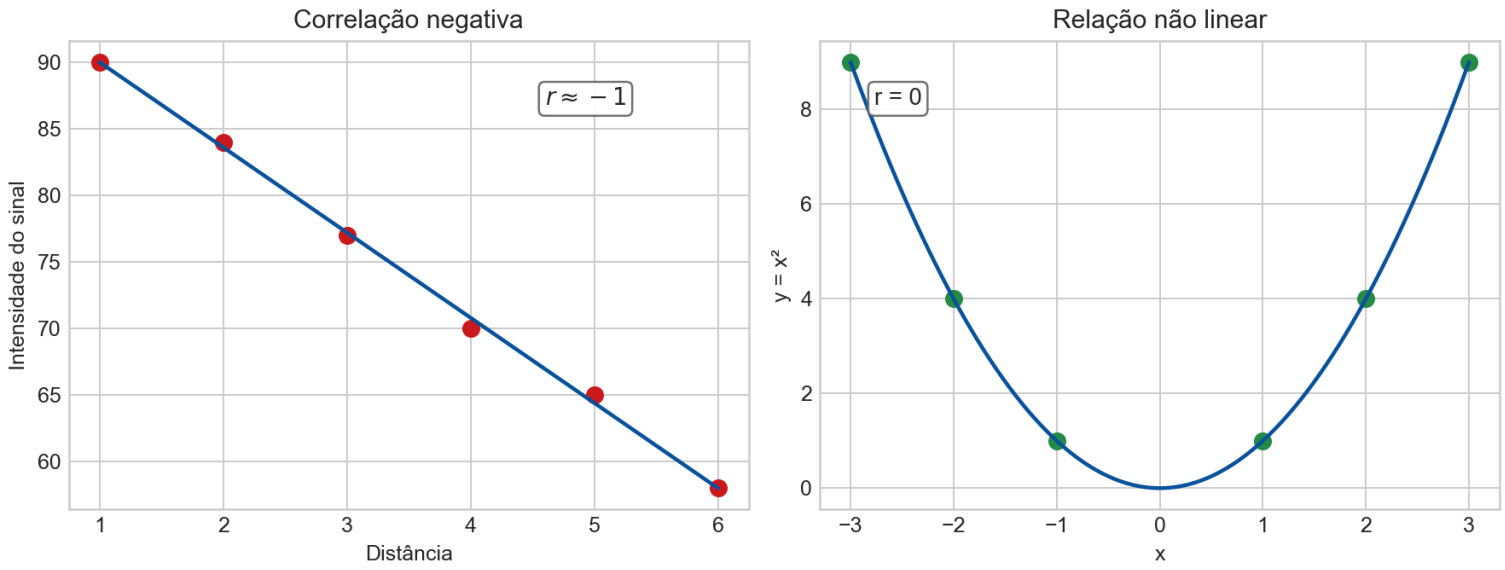

- À esquerda, a associação negativa é bem descrita por uma reta decrescente.
- À direita, a relação é determinística, mas não linear; por isso, Pearson pode ser pequeno mesmo com dependência forte.

O paradoxo de Simpson

Ideia intuitiva: uma tendência pode aparecer em todos os grupos separadamente e, ainda assim, desaparecer ou inverter quando juntamos os dados.

Isso normalmente indica que existe uma **variável de contexto** importante, isto é, um fator que altera a dificuldade dos casos e também a composição da amostra.

- olhar apenas o agregado pode levar a uma conclusão errada;
- comparar grupos homogêneos costuma ser mais informativo;
- em termos práticos, é um alerta para **segmentar antes de concluir**.

Exemplo de Engenharia Elétrica

Dois algoritmos de detecção de falhas em placas eletrônicas, A e B, foram avaliados em dois regimes de ensaio:

- bancada com **baixo ruído**, em que a detecção é mais fácil;
- bancada com **alto ruído**, em que a detecção é mais difícil.

A pergunta correta é: **qual algoritmo é melhor quando as condições de teste são comparáveis?**

Tabela do Exemplo

Cenário	Algoritmo A	Algoritmo B	Melhor no cenário
Baixo ruído	$91/100 = 91{,}0\%$	$228/260 = 87{,}7\%$	A
Alto ruído	$59/100 = 59{,}0\%$	$21/40 = 52{,}5\%$	A
Agregado	$150/200 = 75{,}0\%$	$249/300 = 83{,}0\%$	B

Cada fração significa:

$$\frac{\text{número de detecções corretas}}{\text{número total de placas testadas}}$$

Como Ler a Tabela

- Na linha **baixo ruído**, o algoritmo A acerta 91% e o B acerta 87,7%. Logo, A é melhor nesse cenário.
- Na linha **alto ruído**, o algoritmo A acerta 59% e o B acerta 52,5%. Novamente, A é melhor.
- Portanto, quando a comparação é feita **dentro de cada cenário**, o algoritmo A vence nos dois casos.

Até aqui, não há paradoxo: a leitura por grupo é coerente.

Onde Está o Paradoxo?

O paradoxo aparece na última linha, quando os dados são agregados.

- O algoritmo B foi testado muito mais vezes no cenário de **baixo ruído**, que é mais fácil.
- O algoritmo A ficou mais exposto, proporcionalmente, ao cenário de **alto ruído**, que é mais difícil.
- Assim, a taxa agregada mistura duas coisas: **qualidade do algoritmo** e **dificuldade do ensaio**.

Por isso, o total agregado favorece B, mesmo que A seja melhor em ambos os cenários comparáveis.

Grupos versus agregado

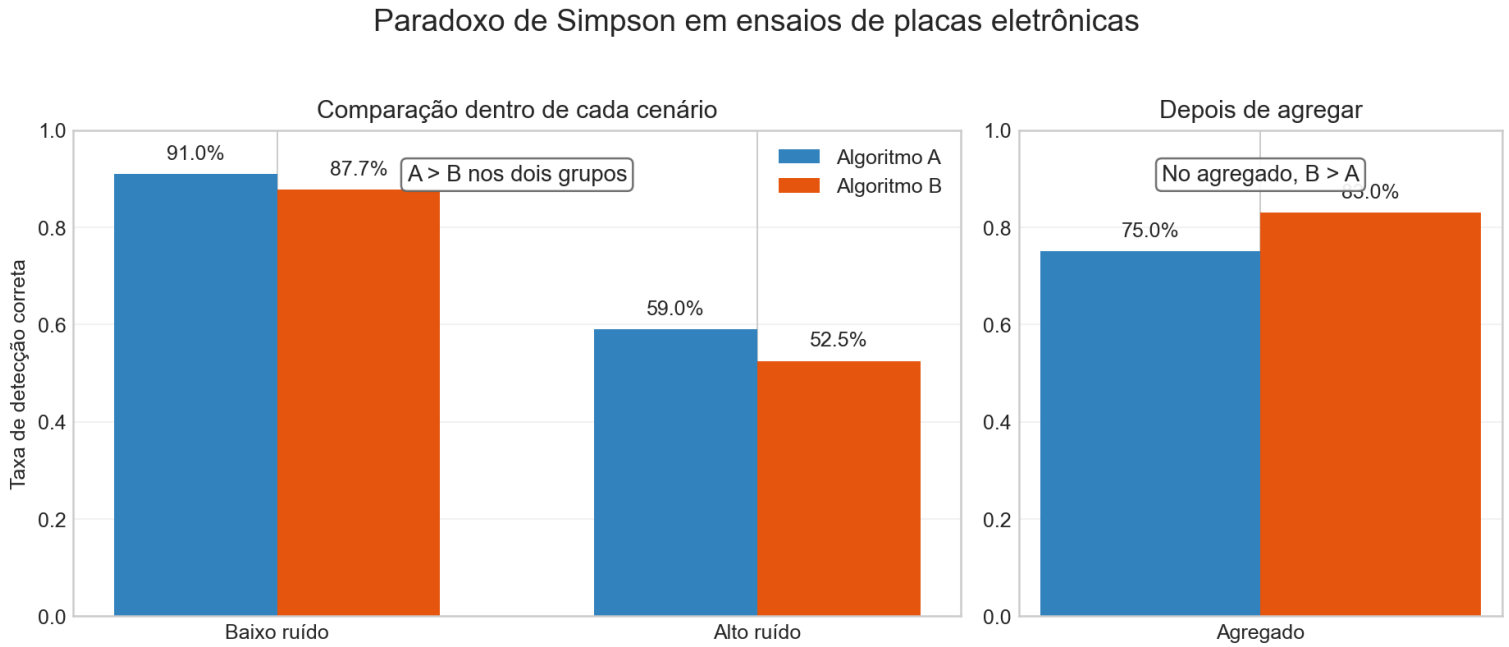

- À esquerda, vemos a comparação justa: dentro de cada cenário, A supera B.
- À direita, vemos o efeito da agregação: o total sugere uma conclusão oposta.

Por Que Isso Importa em Machine Learning?

Em aprendizado de máquina, esse problema aparece quando avaliamos modelos apenas por uma métrica global, como acurácia total.

- Um classificador pode parecer melhor no agregado porque recebeu mais exemplos de uma classe fácil ou majoritária.
- Ao separar por **tipo de falha**, **nível de ruído**, **lote**, **fabricante** ou **subgrupo de usuários**, a conclusão pode mudar.
- Em ML, a recomendação prática é reportar métricas por subgrupo, e não apenas a média global.

Mais alertas sobre correlação

- **Sensibilidade a outliers:** um único ponto extremo pode inflar ou reduzir r.
- **Não linearidade:** uma relação em curva pode gerar correlação próxima de zero.
- **Amostra pequena:** poucos pontos aumentam a incerteza da interpretação.
- **Dados agregados:** misturar grupos diferentes pode distorcer o padrão.
- **Correlação espúria:** tendências temporais comuns e busca massiva por padrões podem gerar associações impressionantes, porém sem significado causal.

Prática recomendada: olhar a correlação junto com gráfico, contexto e segmentação.

Correlação não é causalidade

- Duas variáveis podem variar juntas por causa de uma **terceira variável oculta**.
- Pode existir **causalidade reversa**: Y influencia X, e não o contrário.
- Pode haver **confusão de contexto**: grupos diferentes são misturados.

Em Machine Learning e Ciência de Dados, interpretar mecanismo é diferente de apenas medir associação.

Vamos nos divertir:

`https://www.tylervigen.com/spurious-correlations`

Materiais adicionais: Estatística

Sugestões para aprofundamento:

- repetir as medidas descritivas com outros conjuntos de dados do cotidiano;
- comparar média e mediana em dados com e sem *outliers*;
- construir gráficos de dispersão segmentados por grupos;
- Ler o capítulo 5 de *Data Science do Zero* observando os alertas de interpretação;

Probabilidade

Eventos, dependência e independência

Evento é um conjunto de resultados possíveis de um experimento aleatório.

Exemplos:

- lançar uma moeda e obter cara;
- medir um componente e ele falhar no teste;
- sortear uma peça e ela pertencer ao lote A.

Dois eventos A e B são independentes quando saber que B ocorreu não altera a probabilidade de A:

$$P(A \mid B) = P(A)$$

Exemplos de independência e dependência

Situação	Interpretação
Dois lançamentos de moeda	independentes, se a moeda for honesta
Sorteio sem reposição	dependentes, porque o primeiro resultado altera o segundo

Independência é uma hipótese sobre o mecanismo, não um palpite automático.

Probabilidade condicional

Ideia intuitiva: atualizar a chance de um evento quando recebemos informação adicional.

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Leitura:

- restringimos nossa atenção aos casos em que B ocorreu;
- dentro desse novo universo, perguntamos qual fração também satisfaz A.
- em linguagem de Engenharia, atualizamos a análise quando recebemos uma inspeção, um teste ou uma medição adicional.

Exemplo passo a passo de probabilidade condicional

Em um lote de 100 sensores:

- 20 vieram do fornecedor X;
- entre os do fornecedor X, 5 falharam;
- no total, 12 sensores falharam.

Pergunta: qual a probabilidade de um sensor ter vindo do fornecedor X, sabendo que falhou?

$$P(X \mid F) = \frac{P(X \cap F)}{P(F)} = \frac{5/100}{12/100} = \frac{5}{12} \approx 0{,}417$$

Entre os que falharam, cerca de 41,7% vieram do fornecedor X.

Probabilidade condicional com dois dados

Queremos calcular a probabilidade de os dois dados mostrarem o mesmo valor, dado que a soma foi 8.

Definimos os eventos:

$$A = \{\text{os dois dados mostram o mesmo valor}\}$$

$$B = \{\text{a soma dos dois dados é 8}\}$$

Pela definição de probabilidade condicional:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

Agora vamos identificar os casos em que a soma é 8.

Cálculo da probabilidade

Os resultados possíveis com soma 8 são:

$$(2,6),\ (3,5),\ (4,4),\ (5,3),\ (6,2)$$

Logo, o evento B tem 5 resultados possíveis:

$$P(B) = \frac{5}{36}$$

Entre esses resultados, apenas $(4,4)$ tem valores iguais. Portanto:

$$P(A \cap B) = \frac{1}{36}$$

Assim:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{1/36}{5/36} = \frac{1}{5} = 0{,}2$$

Conclusão:

$$\boxed{P(A \mid B) = \frac{1}{5} = 20\%}$$

Espaço amostral condicionado

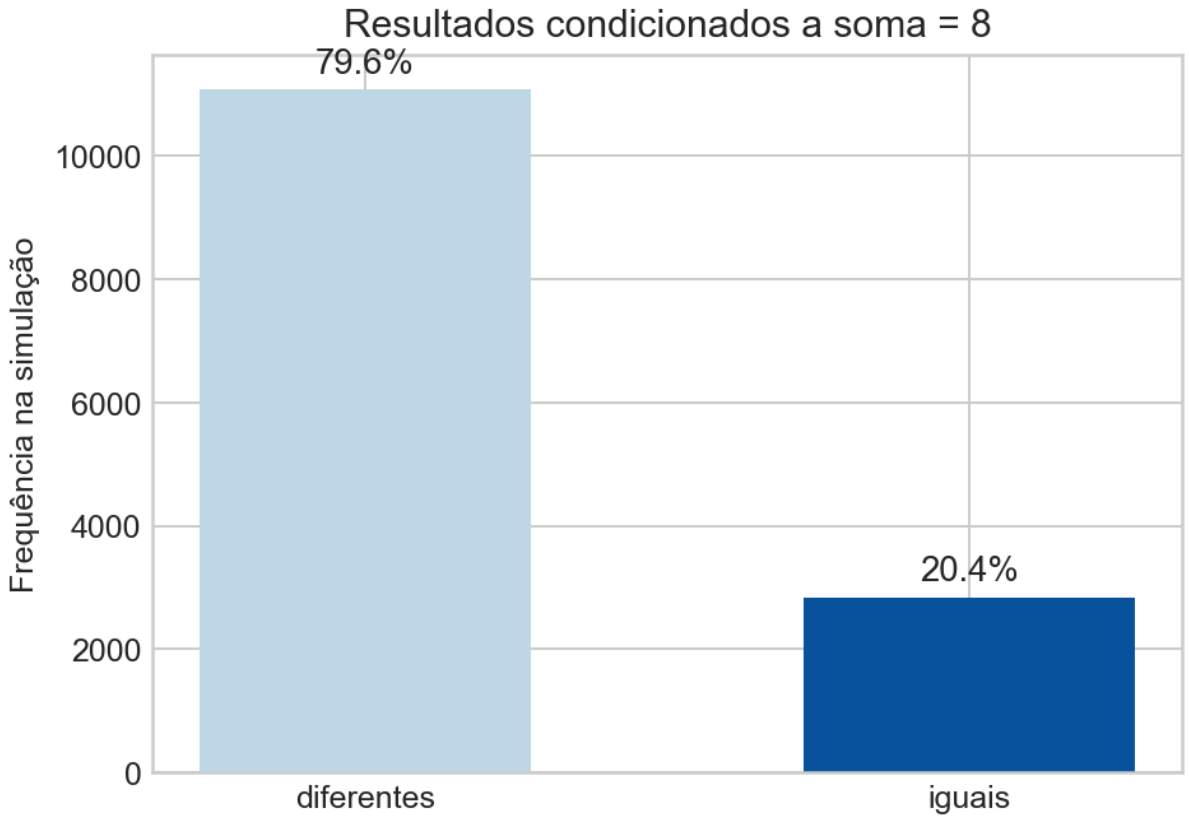

- Ao condicionar pela soma igual a 8, reduzimos o universo de casos possíveis.
- A leitura correta não usa mais os 36 resultados dos dois dados, mas apenas os compatíveis com a evidência observada.

Do condicional ao teorema de Bayes

Partindo das identidades

$$P(A \cap B) = P(A \mid B)P(B) \quad \text{e} \quad P(A \cap B) = P(B \mid A)P(A),$$

obtemos:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}, \qquad P(B) > 0$$

Interpretação no exemplo dos sensores:

- A: o sensor veio do fornecedor X;
- B: o sensor falhou;
- $P(A)$: probabilidade de um sensor ter vindo do fornecedor X;
- $P(B \mid A)$: probabilidade de falha entre os sensores do fornecedor X;
- $P(A \mid B)$: probabilidade de o sensor ser do fornecedor X, dado que falhou;
- $P(B)$: probabilidade total de falha no lote.

Exemplo prático de Bayes

Um teste automático detecta defeitos em placas:

- 2% das placas são realmente defeituosas;
- se a placa é defeituosa, o teste acusa positivo em 95% dos casos;
- se a placa é boa, o teste ainda acusa positivo em 4% dos casos.

Queremos $P(\text{defeituosa} \mid \text{teste positivo})$:

$$\frac{0{,}95 \cdot 0{,}02}{0{,}95 \cdot 0{,}02 + 0{,}04 \cdot 0{,}98} \approx 0{,}326$$

- Mesmo com teste bom, um positivo ainda não garante defeito.
- O defeito real é raro: apenas 2%, e essa taxa base pesa muito.

Interpretação do exemplo de Bayes

- Falsos positivos ocorrem pouco, mas incidem sobre um grupo muito maior de placas boas.
- Por isso, a probabilidade final após teste positivo fica em torno de 32,6%, e não 95%.
- A leitura correta combina desempenho do teste, frequência real do evento e custo de errar a decisão.

Erro comum: confundir $P(\text{positivo} \mid \text{defeituosa})$ com $P(\text{defeituosa} \mid \text{positivo})$.

Verdadeiros e falsos positivos

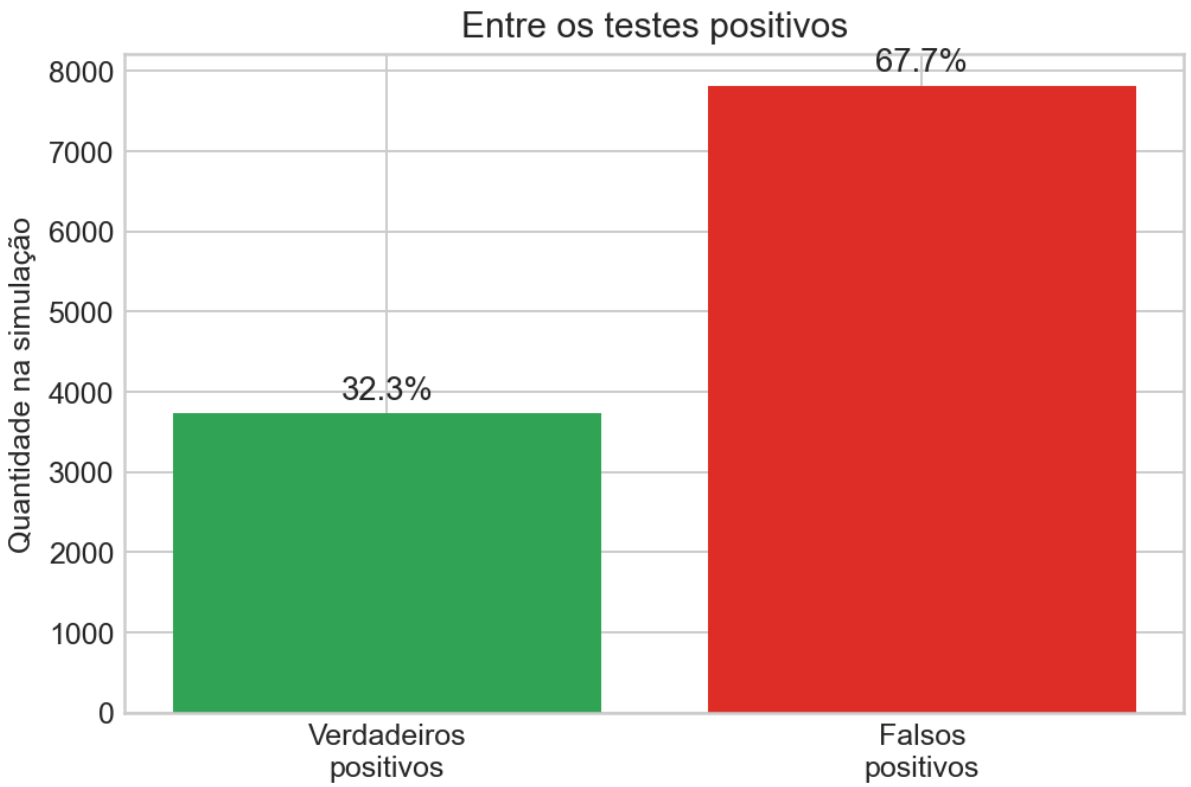

- Mesmo com falso positivo relativamente baixo, ainda surgem muitos positivos em placas boas.
- A figura ajuda a tornar concreta a ideia de taxa base.

Variáveis aleatórias

Ideia intuitiva: associar um número ao resultado de um experimento aleatório.

- **Discreta**: assume valores isolados, como número de falhas em 10 testes.
- **Contínua**: assume valores em um intervalo, como tempo de vida de um componente.

Valor esperado: resume o "valor médio" de longo prazo.

Distribuições contínuas

Para variáveis contínuas, a probabilidade em um ponto isolado é zero:

$$P(X = a) = 0$$

A informação relevante está na área sob a função densidade:

$$P(a \leq X \leq b) = \int_a^b f(x)\, dx$$

Interpretação:

- a densidade mede concentração, não probabilidade pontual;
- intervalos mais largos ou regiões mais densas acumulam mais probabilidade.

Função distribuição acumulada (CDF)

A função distribuição acumulada de uma variável aleatória contínua é:

$$F(x) = P(X \leq x)$$

Como interpretar:

- a CDF informa quanta probabilidade já foi acumulada até o ponto x;
- ela sempre cresce de 0 até 1;
- em variáveis contínuas, a CDF é obtida acumulando a área sob a densidade.

Exemplo: se $F(1{,}0) = 0{,}84$, então há cerca de 84% de chance de observar $X \leq 1{,}0$.

Figura: CDF da normal padrão

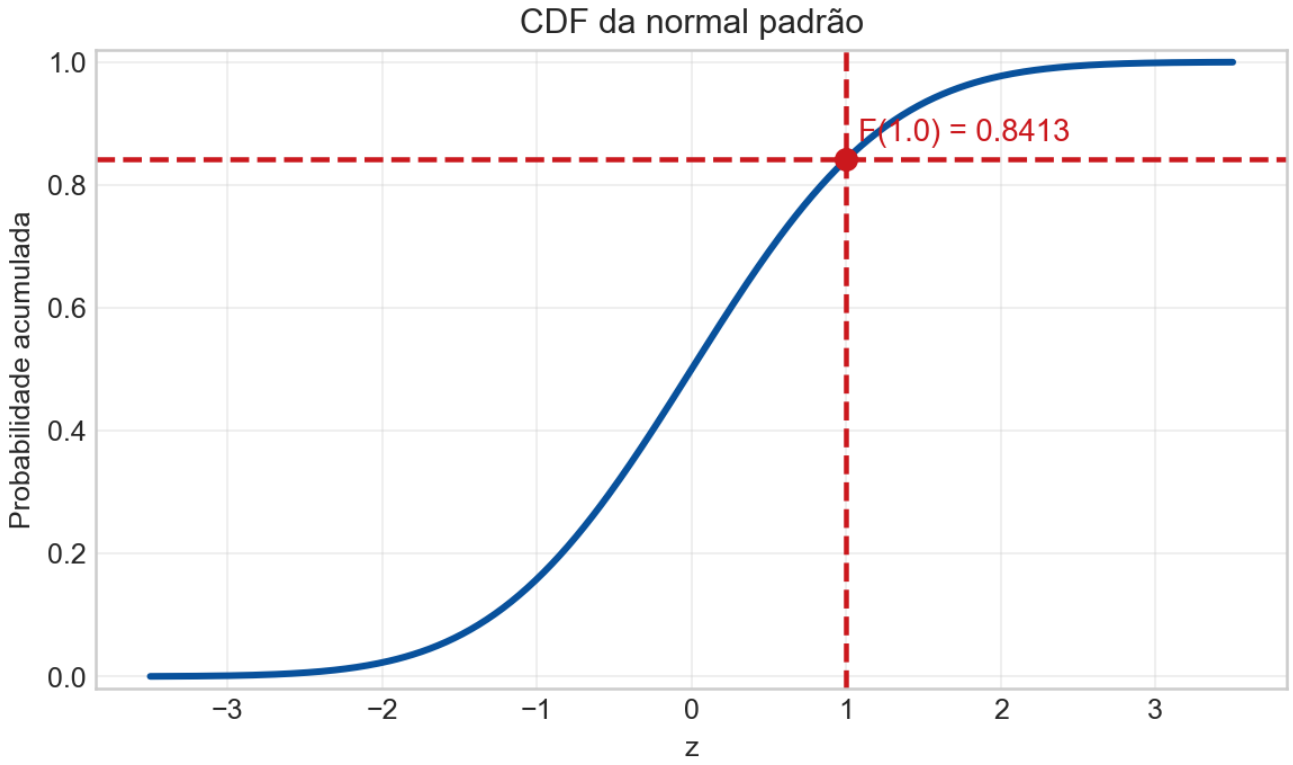

- A curva mostra a probabilidade acumulada até cada valor de x.
- No ponto $x = 1$, lemos $F(1) = P(Z \leq 1) \approx 0{,}8413$.
- A leitura visual ajuda a ver que a CDF cresce continuamente de 0 até 1.

Python: calculando uma CDF

```
from statistics import NormalDist

normal_padrao = NormalDist(mu=0, sigma=1)
valor = normal_padrao.cdf(1.0)

print(valor)
```

Esse cálculo retorna $P(Z \leq 1)$ para a normal padrão.

Distribuição normal

- É uma curva em forma de sino, simétrica em torno da média μ.
- O desvio padrão σ controla o espalhamento.
- Surge com frequência em medições sujeitas à soma de muitos pequenos efeitos aleatórios.

Regra empírica:

- cerca de 68% dos valores ficam em $\mu \pm 1\sigma$;
- cerca de 95% ficam em $\mu \pm 2\sigma$;
- cerca de 99,7% ficam em $\mu \pm 3\sigma$.

Exemplo de normal em medições

Suponha que o erro de medição de uma tensão seja aproximadamente normal com

$$\mu = 0 \quad \text{e} \quad \sigma = 0{,}2 \text{ V}$$

Então, aproximadamente:

- 68% dos erros ficam entre $-0{,}2$ V e 0,2 V;
- 95% ficam entre $-0{,}4$ V e 0,4 V.

Isso ajuda a comunicar incerteza de medição de forma prática.

Figura: curvas normais com mesmo centro

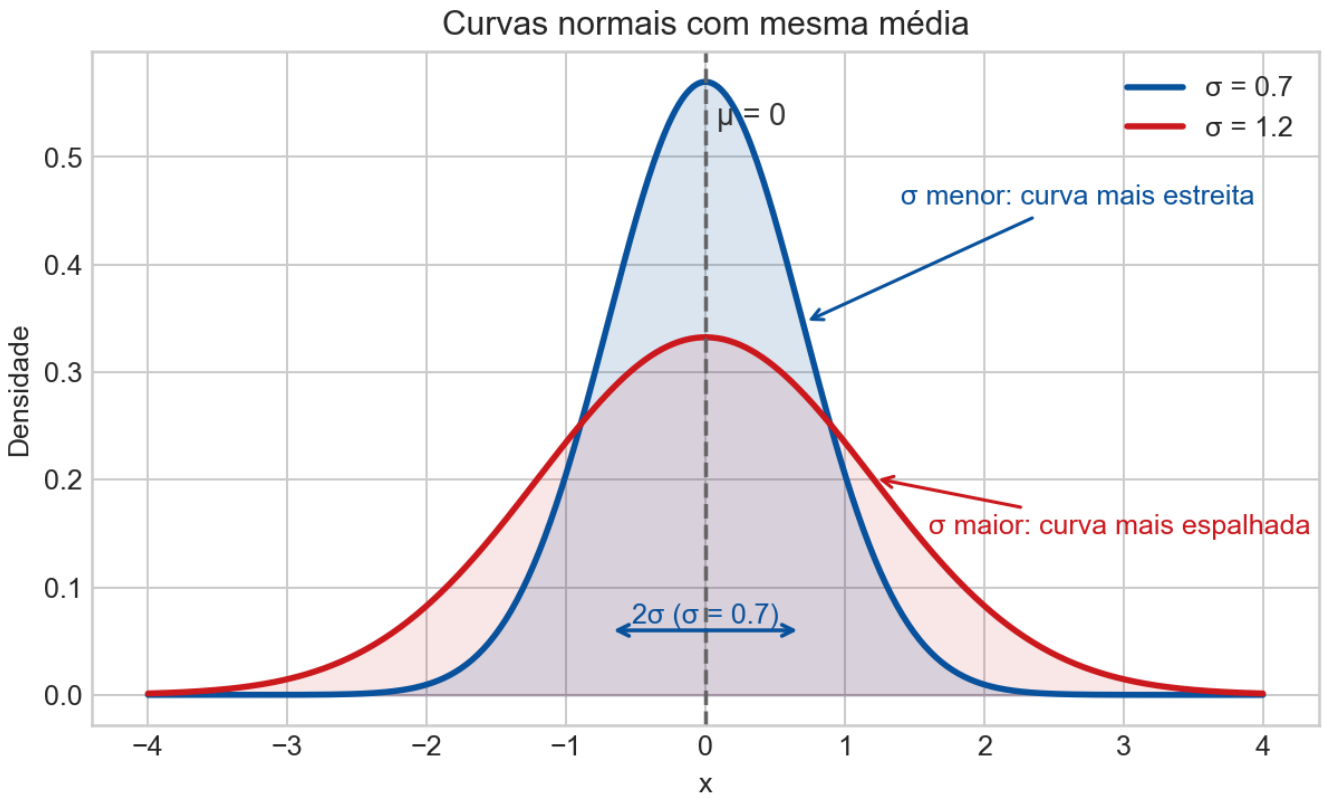

- A média μ marca o centro da curva e o eixo de simetria da distribuição.
- O desvio padrão σ mede o espalhamento.

Teorema do limite central

Ideia intuitiva: mesmo que a distribuição original não seja normal, a distribuição das médias amostrais tende a ficar aproximadamente normal quando o tamanho da amostra cresce.

Em termos simples:

- sorteamos muitas amostras do mesmo tamanho;
- calculamos a média de cada amostra;
- observamos que essas médias se organizam de forma mais regular e menos assimétrica.

Isso explica por que médias são tão importantes em inferência e controle estatístico.

Figura: distribuição original x médias amostrais

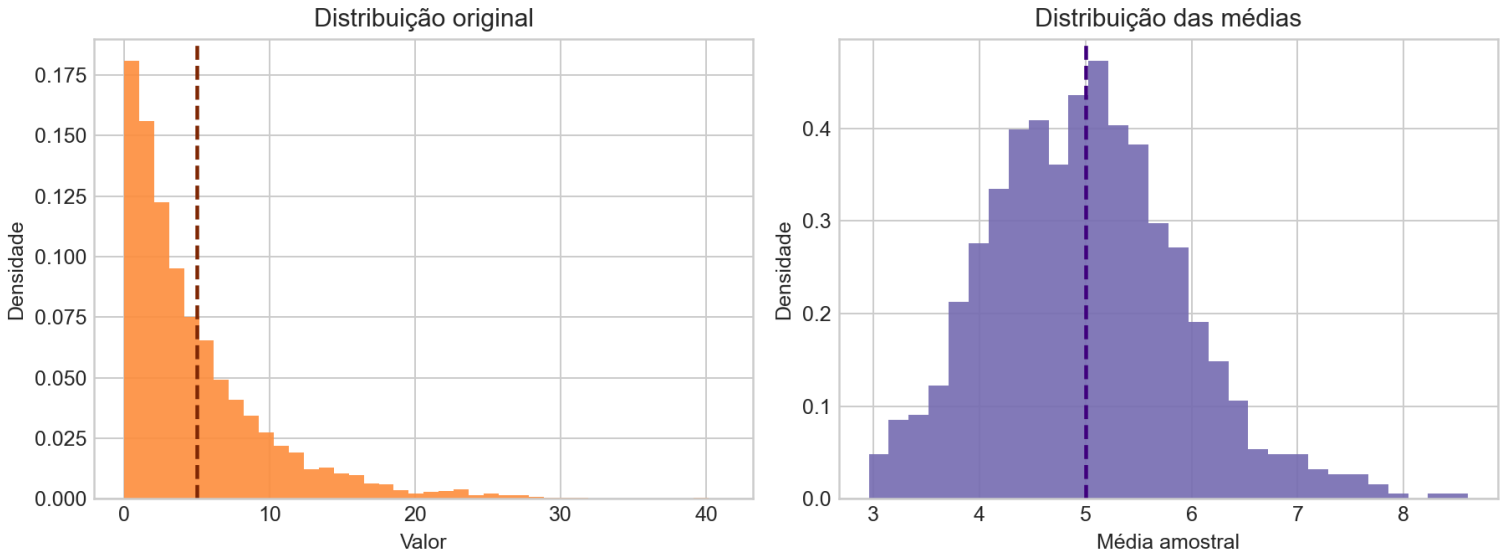

- A distribuição original é assimétrica.
- As médias amostrais aparecem mais concentradas e com forma mais próxima da normal, mesmo sem a população original ser normal.

Interpretação do teorema do limite central

- A distribuição exponencial é assimétrica, mas as médias de amostras de tamanho 30 já tendem a parecer mais simétricas.
- As médias amostrais variam menos do que observações individuais.
- Em engenharia experimental, isso justifica o uso de médias para reduzir ruído.
- A média das médias amostrais se aproxima da média populacional;
- A dispersão das médias é menor.

Cuidado: o teorema não diz que qualquer amostra pequena é normal.

Síntese da aula

- Estatística descritiva resume dados, mas a interpretação correta depende de contexto, dispersão e valores extremos.
- Correlação quantifica associação linear; gráficos e segmentação evitam conclusões ingênuas.
- Probabilidade condicional e Bayes formalizam atualização de informação em diagnóstico e inspeção.
- Distribuição normal e limite central explicam por que médias e faixas de variação aparecem tanto em Engenharia.

Material adicional opcional: `statsmodels`

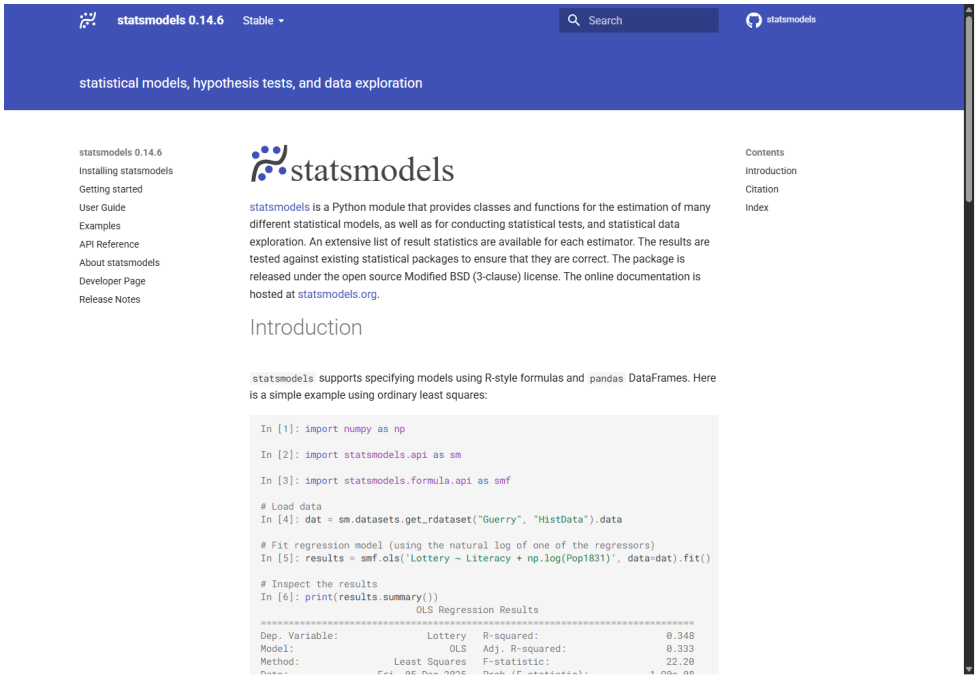

- `statsmodels` vale mais como ponte para regressão, intervalos de confiança e inferência.
- Não é necessário para compreender a aula de hoje, mas é uma boa referência para quem quiser aprofundar em estatística com ferramentas mais formais.
- `https://www.statsmodels.org/stable/`

Exercícios sugeridos I: estatística descritiva

1. Um sensor de vibração registrou as amplitudes $3{,}1\ \text{mm}, 3{,}0\ \text{mm}, 3{,}2\ \text{mm}, 3{,}1\ \text{mm}, 3{,}0\ \text{mm}, 6{,}4\ \text{mm}$. Calcule média, mediana, amplitude e desvio padrão. Discuta qual medida de tendência central melhor representa o comportamento usual.
2. Dois lotes de resistores foram submetidos a um ensaio de aquecimento, e registrou-se o tempo (em segundos) até atingirem a temperatura de regime permanente, em segundos:

$$A = (11, 12, 12, 13, 12), \quad B = (8, 10, 12, 14, 16)$$

Compare média, mediana e dispersão.

Exercícios sugeridos II: correlação e crítica

1. Uma equipe mediu temperatura ambiente e consumo de energia de uma sala durante 8 dias e encontrou correlação positiva alta. Liste ao menos três explicações possíveis e diga por que isso não prova causalidade direta.
2. Construa um pequeno exemplo numérico em que a correlação linear entre x e y seja baixa, mas a relação entre as variáveis seja claramente não linear.

Exercícios sugeridos III: probabilidade condicional e Bayes

1. Em uma linha de montagem, 15% das peças vêm da máquina A. Sabe-se que 6% das peças da máquina A são defeituosas e 2% das demais também são defeituosas. Se uma peça escolhida ao acaso é defeituosa, qual a probabilidade de ela ter vindo da máquina A?
2. Ao lançar dois dados honestos, calcule $P(\text{pelo menos um } 6 \mid \text{soma maior que } 9)$. Organize o espaço amostral condicionado antes de calcular.

Exercícios sugeridos IV: normal e limite central

1. O erro de um instrumento é aproximadamente normal com média 0 e desvio padrão 0,5 unidade. Use a regra empírica para estimar a faixa que contém aproximadamente 95% dos erros.
2. Uma variável aleatória tem distribuição bastante assimétrica. Explique, com suas palavras, por que a distribuição das médias de amostras de tamanho 40 tende a ser mais próxima da normal do que a distribuição original. Em seguida, proponha uma simulação computacional simples para verificar isso.

Materiais adicionais e referências

Leitura e revisão

- Grus, Joel. *Data Science do Zero*. Capítulos 5 e 6.
- Revisar definições de média, variância, correlação, probabilidade condicional e Bayes.
- Explorar no notebook como gráficos mudam ao incluir *outliers* ou ao alterar o tamanho amostral.
- Como leitura opcional para continuidade: documentação oficial do `statsmodels`, útil em regressão e inferência estatística.

Experimentos computacionais

- alterar os dados do paradoxo de Simpson e verificar quando a inversão ocorre;
- simular testes diagnósticos com diferentes taxas base;
- repetir a simulação do limite central para distribuições diferentes.