Aprendizado de Máquina

Samir A. M. Martins[1]

[1]Universidade Federal de São João del-Rei
Departamento de Engenharia Elétrica
São João del-Rei, MG – Brasil

Graduação em Engenharia Elétrica

Roteiro da aula

1. O que é aprendizado de máquina
2. Subajuste e sobreajuste
3. O dilema Viés–variância
4. Correção
5. Extração e seleção de recursos
6. Exercícios sugeridos

Cenário analisado

Desejamos detectar falhas em um motor de indução usando sinais de corrente, vibração e temperatura.

- Os sinais são ruidosos e mudam com carga e ambiente.
- Nem sempre há um modelo físico completo para a decisão.
- Precisamos transformar dados em diagnóstico, previsão ou alarme.

Pergunta central

Como aprender padrões úteis sem apenas decorar o conjunto de treino?

Modelagem Matemática

- Modelar é representar um sistema real por meio de uma abstração matemática.
- Em aprendizado de máquina, buscamos uma função que relacione as variáveis de entrada com a saída estimada:

$$\hat{y} = f_\theta(\mathbf{x})$$

- $\mathbf{x} = [x_1,\ x_2,\ \ldots,\ x_n]^T$: vetor de entrada, formado por uma ou mais variáveis do problema.
- Cada componente x_i representa uma entrada específica, como temperatura, tensão, corrente, frequência ou outra característica observada.

Modelagem Matemática

- f_θ: modelo matemático parametrizado que transforma a entrada em uma previsão.
- θ: conjunto de parâmetros do modelo, ajustados durante o treinamento.
- $\hat{y}$: saída estimada pelo modelo.
- y: saída real ou valor de referência.
- **Critério de avaliação**: compara $\hat{y}$ com y usando diferentes métricas de erro.

Exemplo de modelagem no cenário analisado

- No problema de detecção de falhas, cada observação do motor pode ser representada por um vetor de entrada:

$$\mathbf{x} = [x_1,\ x_2,\ x_3,\ \ldots,\ x_n]^T$$

- Aqui, $\mathbf{x}$ reúne características extraídas dos sinais medidos, por exemplo:
  - valor eficaz da corrente;
  - amplitude de vibração;
  - temperatura do estator;
  - frequência dominante no espectro;
  - índice de desequilíbrio entre fases.
- Assim, cada componente x_i representa uma variável medida ou calculada a partir dos sinais do motor.

Saída, modelo e parâmetros

- A variável y representa a saída real de interesse, por exemplo:

$$y \in \{\text{normal},\ \text{falha}\}$$

- O modelo recebe as entradas e produz uma estimativa:

$$\hat{y} = f_\theta(\mathbf{x})$$

- f_θ é a função que relaciona os sinais medidos com a condição do motor.
- Os parâmetros θ são ajustados durante o treinamento para que o modelo aprenda padrões úteis nos dados.
- Assim, $\hat{y}$ é o diagnóstico previsto pelo modelo, enquanto y é a condição real usada como referência na avaliação.

Etapas da modelagem

Da medição à decisão em um problema de Machine Learning

Figura 1. Etapas da modelagem orientado a dados: medições e atributos alimentam o modelo, que gera uma decisão ou estimativa.

O que é aprendizado de máquina

O que é Aprendizado de Máquina?

- Aprendizado de máquina é o estudo de modelos que aprendem padrões a partir de dados.
- Em vez de programar explicitamente todas as regras do problema, usamos dados para ajustar os parâmetros do modelo.
- O objetivo não é apenas reproduzir bem os dados já observados, mas **generalizar**, isto é, produzir boas respostas para novos dados.

Quando isso é útil em Engenharia?

Quando o fenômeno é complexo, quando o modelo físico é incompleto ou quando precisamos de uma aproximação para decisão em tempo real.

Exemplo: aprender relação entre carga e temperatura

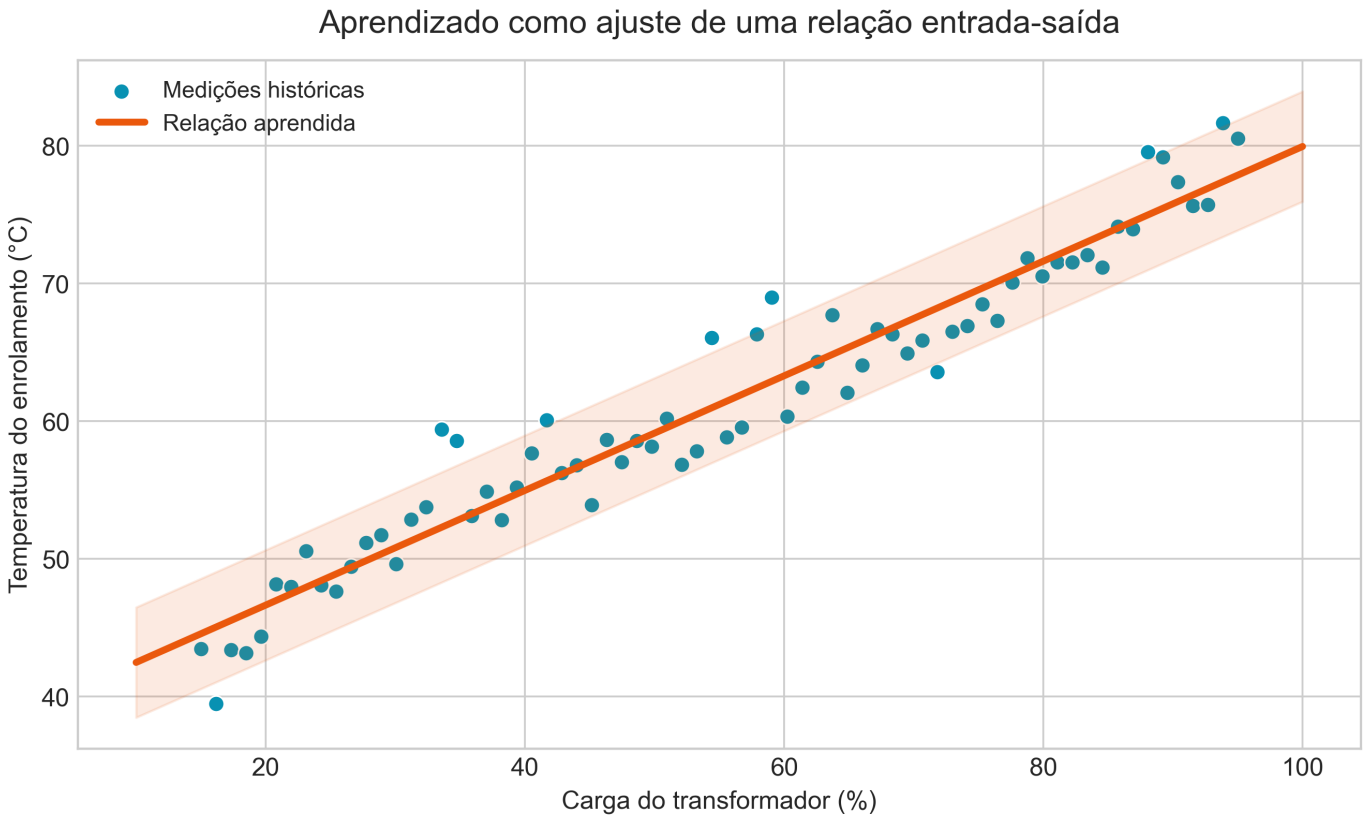

Figura 2. Exemplo de Machine Learning em Engenharia Elétrica: o modelo ajusta a relação entre carga e temperatura a partir de medições históricas.

Subajuste e sobreajuste

Viés e Variância

Viés: erro por simplificação excessiva

- **Viés** é o erro causado por hipóteses muito simplificadoras no modelo.
- Um modelo com alto viés tende a não capturar adequadamente o comportamento real dos dados.

Variância: sensibilidade excessiva aos dados

- **Variância:** sensibilidade do modelo a pequenas variações.
- Um modelo com alta variância se ajusta demais aos dados vistos e perde capacidade de generalização.
- Nesse caso, o desempenho no treinamento pode ser muito bom, mas piora em novos dados.

Subajuste e sobreajuste

Subajuste

Modelo simples demais.

- alto viés;
- perde a estrutura do problema;
- erro alto até em treino.

Sobreajuste

Modelo complexo demais.

- alta variância;
- ajusta ruído do treino;
- falha ao generalizar.

Ideia-chave

- Um bom modelo aprende o padrão relevante do sistema, não as flutuações acidentais de uma amostra específica.
- Aprender não é decorar ponto a ponto; é capturar regularidades.

Visualizando o ajuste do modelo

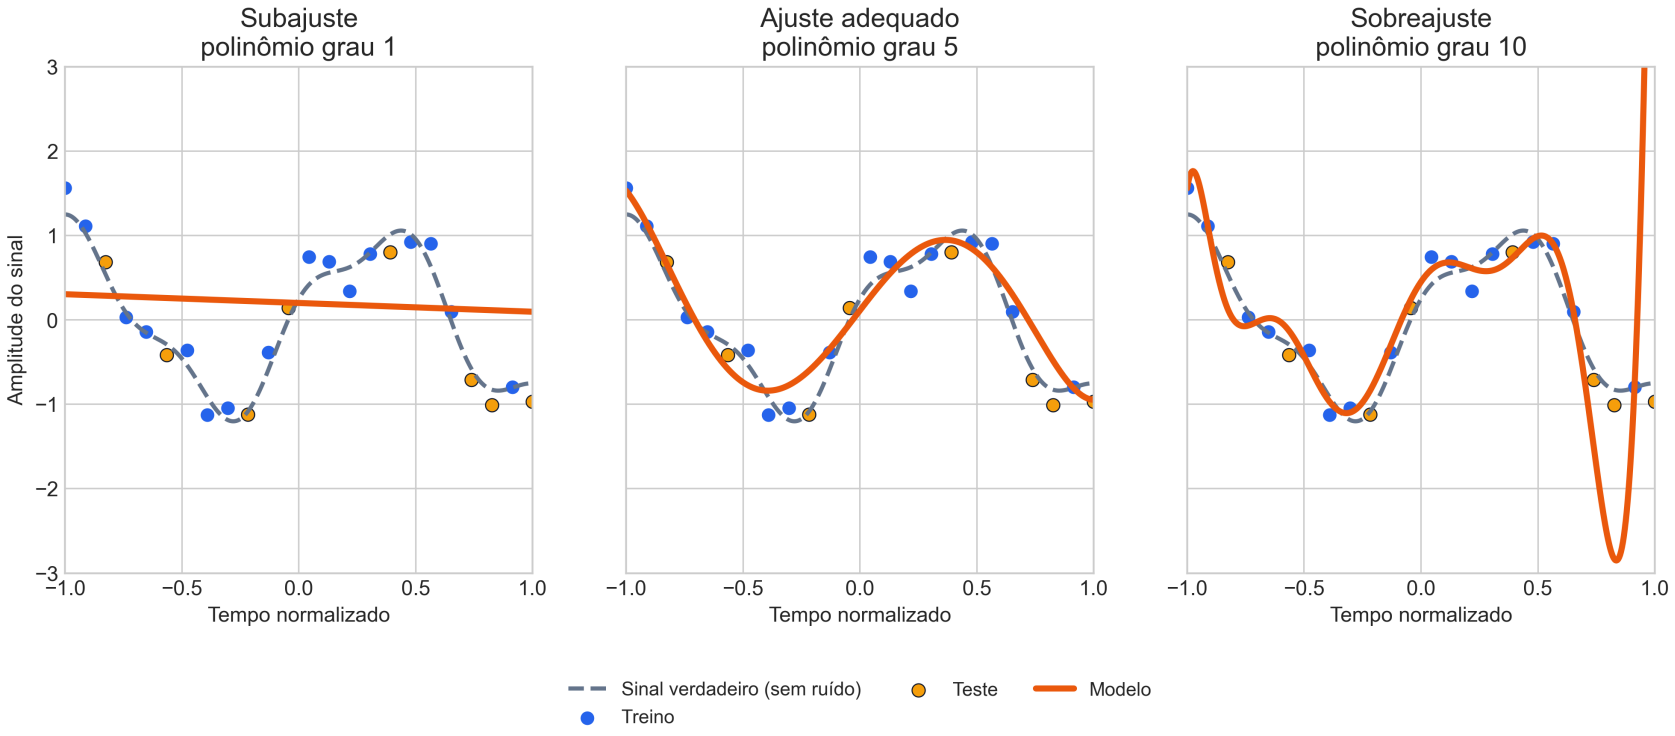

Figura 3. Três regimes de complexidade do modelo: subajuste, ajuste adequado e sobreajuste ao tentar representar um sinal com ruído.

Leitura da figura

- **Subajuste**: a hipótese é pobre demais para capturar a curvatura do fenômeno.
- **Ajuste adequado**: o modelo acompanha a tendência dominante sem oscilar demais.
- **Sobreajuste**: a curva segue detalhes espúrios que pertencem ao ruído do conjunto de treino.

Exemplo

Em sinais de corrente ou vibração, um modelo superajustado pode parecer excelente em bancada e falhar quando o equipamento muda de carga, ambiente ou regime.

O Dilema Viés–Variância

O dilema viés–variância

- **Viés**: erro sistemático causado por um modelo rígido demais.
- **Variância**: sensibilidade excessiva a mudanças no conjunto de treino.
- Aumentar complexidade costuma reduzir viés, mas tende a aumentar variância.

Compromisso

Boa generalização normalmente aparece em uma faixa intermediária de complexidade, e não nos extremos.

Curva qualitativa do trade-off

Figura 5. Trade-off viés–variância: ao aumentar a complexidade, o viés tende a cair, a variância tende a subir e o erro de generalização costuma formar uma curva em U.

- Viés cai com a complexidade.
- Variância cresce com a complexidade.
- O erro esperado em dados novos forma uma curva em “U”.

Como reduzir viés ou variância?

Para reduzir viés

- modelo mais expressivo;
- características mais informativas;
- melhor representação do fenômeno.

Para reduzir variância

- mais dados;
- redução de complexidade;
- regularização (tratado nas próximas aulas).

Correção

Correção em classificação

- Em problemas de classificação, não basta saber apenas quantos acertos o modelo teve.
- Também precisamos entender **quais tipos de erro** ele comete.
- Em manutenção preditiva, deixar de detectar uma falha real é mais grave do que emitir um falso alarme.

Resultados possíveis em classificação binária

- Considerando a classe positiva como **falha**, temos quatro resultados possíveis:
- **VP** (verdadeiro positivo): o modelo previu **falha** e a condição real também era **falha**.
- **FP** (falso positivo): o modelo previu **falha**, mas a condição real era **normal**.
- **FN** (falso negativo): o modelo previu **normal**, mas a condição real era **falha**.
- **VN** (verdadeiro negativo): o modelo previu **normal** e a condição real também era **normal**.

Métricas para avaliação em classificação

$$\text{Precisão} = \frac{VP}{VP + FP}$$

- **Precisão**: entre todos os casos classificados como **falha**, quantos eram realmente falhas.

$$\text{Recall} = \frac{VP}{VP + FN}$$

- **Recall**: entre todas as falhas reais, quantas foram corretamente detectadas.

$$F_1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

- $\mathbf{F_1}$: medida que busca equilibrar precisão e recall (média harmônica entre Precisão e Recall).

Acurácia sozinha pode enganar

- Quando falhas são raras, prever sempre “normal” pode gerar acurácia aparentemente alta.
- Isso não significa que o classificador seja útil.
- Em Engenharia, a métrica deve refletir o custo operacional do erro.

Regra prática

Escolha a métrica a partir da decisão real: segurança, manutenção, custo, interrupção ou inspeção.

Exemplo visual de correção

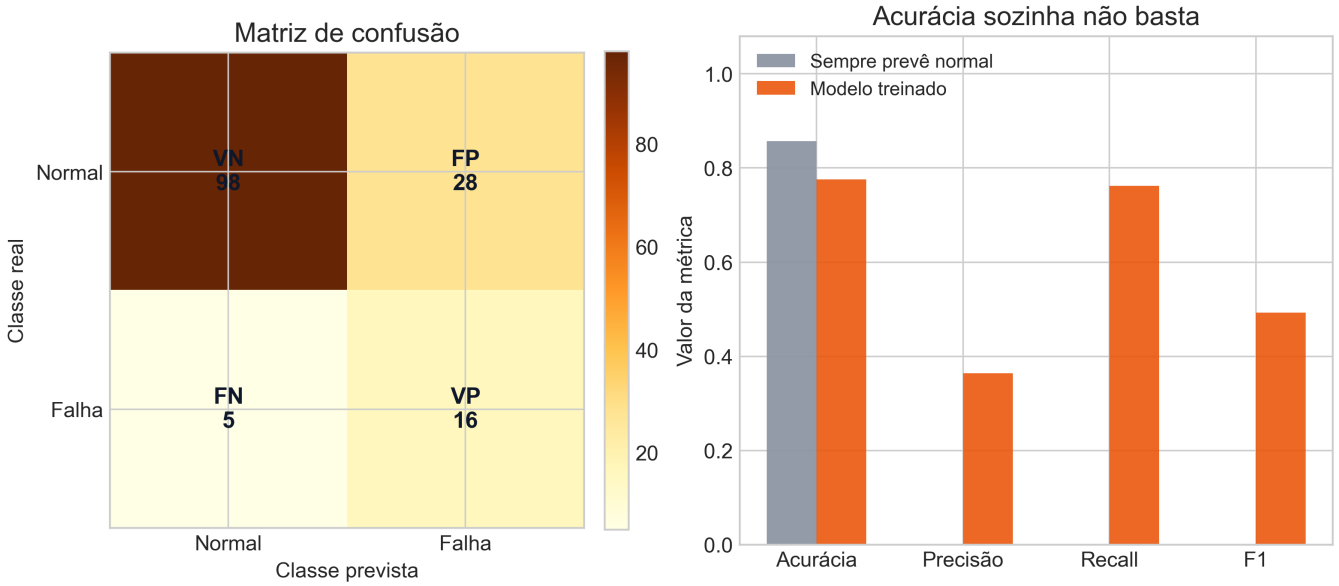

Figura 4. Matriz de confusão para um classificador de falhas em motores, destacando por que acurácia, precisão e recall respondem a perguntas diferentes sobre a correção do modelo.

Extração e seleção de recursos

Features: por que importam?

- Em sinais elétricos, o dado bruto pode ser extenso e pouco interpretável.
- Extraímos **recursos** para resumir informação relevante.
- Exemplos: RMS, fator de crista, fator de distorção harmônica, energia, conteúdo harmônico ...

Seleção de recursos

Depois da extração, escolhemos quais variáveis merecem entrar no modelo, removendo redundância e ruído.

Do sinal bruto às variáveis úteis

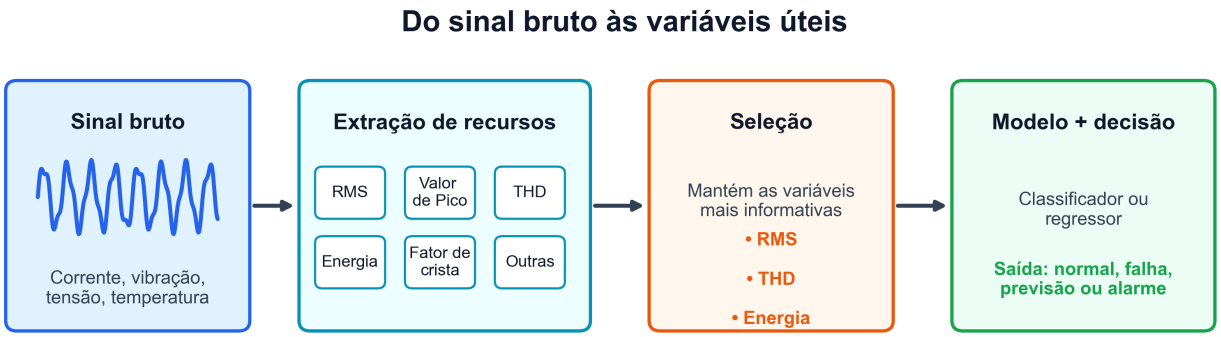

Figura 6. Fluxo de extração e seleção de recursos: do sinal bruto são derivados atributos no tempo e na frequência, dos quais permanecem os mais informativos para classificação.

Impacto prático

Seleção de features reduz custo computacional, melhora interpretação e facilita implementação em sistemas embarcados.

Por que a extração de características ajuda?

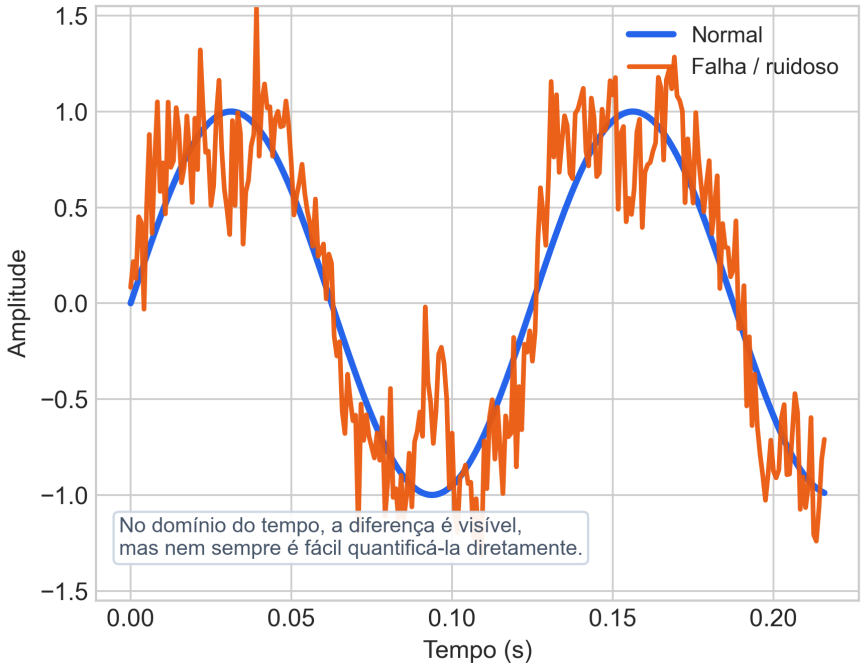

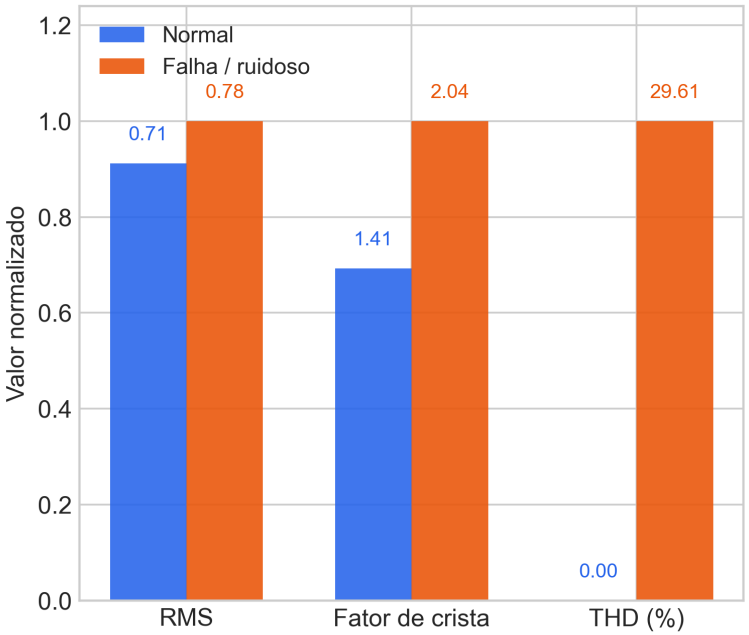

À esquerda, observa-se o sinal no domínio do tempo; à direita, medidas resumidas como RMS, fator de crista e THD tornam mais clara a distinção entre operação normal e sinal com falha.

Síntese da aula

1. Modelagem define entradas, saídas e objetivo do problema.
2. Aprendizado de máquina ajusta modelos com base em dados.
3. Bons modelos evitam subajuste e sobreajuste.
4. Correção exige métricas coerentes com o custo dos erros.
5. O dilema viés–variância orienta a escolha da complexidade.
6. Características bem extraídas e selecionadas melhoram desempenho do modelo e a interpretabilidade do problema.

Exercícios sugeridos

Exercícios sugeridos: teoria e análise

1. Em um sistema de manutenção preditiva para motores, discuta qual erro é mais crítico: **falso positivo** ou **falso negativo**. Justifique em termos de custo, segurança e disponibilidade.
2. Um modelo para estimar a temperatura de um transformador apresenta erro alto tanto em treino quanto em teste. Que evidência isso traz sobre **subajuste**, viés e complexidade do modelo?
3. Um classificador obteve acurácia de 97% na detecção de falhas, mas recall de apenas 35%. Explique por que esse resultado pode ser inadequado em Engenharia Elétrica.
4. Cite quatro features úteis para diagnosticar condições anormais em sinais elétricos ou de vibração e explique, qualitativamente, o que cada uma representa.

Exercícios sugeridos: programação com dados sintéticos I

1. Gere dados sintéticos não lineares para relacionar **carga** e **temperatura** de um equipamento. Ajuste polinômios com `np.polyfit` para diferentes graus e compare erro de treino e teste para discutir viés–variância. Use pelo menos quatro graus distintos, por exemplo 1, 2, 4 e 8.
2. Represente graficamente os ajustes e identifique, com justificativa, qual caso indica subajuste, ajuste adequado e sobreajuste.
3. Relate como a escolha do grau altera viés, variância e capacidade de generalização.

Sugestão

Reutilize o notebook da aula como ponto de partida e registre o erro em treino e em teste para cada polinômio.

Referência-base

Bibliografia básica

GRUS, Joel. *Data Science do Zero: Noções Fundamentais com Python*. 2. ed. Rio de Janeiro: Alta Books, 2021.

- Capítulo 11: *Aprendizado de Máquina*
- Tópicos centrais usados nesta aula:
  - Modelagem
  - O que é Machine Learning?
  - Overfitting e Underfitting (Sobreajuste e Subajuste)
  - Correção
  - O Dilema Viés-Variância
  - Extração e Seleção de Características