# Introdução às Técnicas de Classificação

Samir A. M. Martins

Universidade Federal de São João del-Rei
Departamento de Engenharia Elétrica
São João del-Rei, MG – Brasil

Graduação em Engenharia Elétrica

# Ponto de partida

**Objetivo desta primeira parte**

Entender o que caracteriza um problema de classificação.

- Classificação é, na maioria das aplicações, um problema de **aprendizado supervisionado**.
- Há exemplos de entrada acompanhados de uma **resposta conhecida**.
- A saída esperada não é um valor contínuo, mas uma **categoria**.
- Em Engenharia Elétrica, essas categorias podem representar estados, alarmes, tipos de falha ou regimes de operação.

# Aprendizado supervisionado

## Ideia central

No aprendizado supervisionado, o modelo aprende a partir de pares

$$(\text{entrada}, \text{saída})$$

em que a saída correta já é conhecida.

- O conjunto de treinamento contém exemplos rotulados.
- O objetivo é aprender uma regra que generalize para novos casos.

# Classificação e regressão

## Classificação

- A saída é uma **classe**.
- Ex.: normal/anormal.
- Ex.: spam/não spam.
- Ex.: falha elétrica tipo A, B ou C.

## Regressão

- A saída é um **valor numérico**.
- Ex.: prever temperatura.
- Ex.: estimar consumo.
- Ex.: prever tensão ou potência.

**Resumo:** em ambos há rótulos, mas na classificação a saída é categórica; na regressão, numérica.

# Aprendizado não supervisionado

**Ideia central**

No aprendizado não supervisionado, os dados de entrada são fornecidos **sem rótulos**.

- O objetivo não é prever uma resposta conhecida.
- O foco é identificar **estruturas**, **padrões** ou **relações** nos dados.

# Supervisionado vs. não supervisionado

| **Aprendizado supervisionado** | **Aprendizado não supervisionado** |
|---|---|
| Usa dados com rótulos. | Usa dados sem rótulos. |
| Aprende uma relação entre entrada e saída. | Busca padrões nos próprios dados. |
| Permite classificação e regressão. | Permite agrupamento e organização estrutural. |
| Ex.: classificar condições de operação de um motor como normal, sobrecarga ou falha. | Ex.: agrupar perfis de consumo de energia ou regimes de operação semelhantes. |

# Classificação em Engenharia Elétrica

- Classificação de faltas em linhas de transmissão em categorias como **fase-terra**, **fase-fase**, **dupla fase-terra** e **trifásica**;
- identificação de **afundamento**, **elevação**, **interrupção** e **transitórios** em sinais de qualidade da energia elétrica;
- diagnóstico do estado de transformadores a partir de ensaios ou monitoramento, classificando a condição em **normal**, **envelhecimento de isolação**, **descarga parcial** ou **sobreaquecimento**;
- classificação do estado operacional de motores de indução em **operação normal**, **desbalanceamento de tensão**, **falha de rolamento** ou **barra quebrada no rotor**;

O modelo recebe medições como tensão, corrente, frequência, harmônicos ou atributos extraídos dos sinais e associa cada observação a uma classe previamente definida.

## Fluxo geral

Todos esses métodos aprendem uma regra

$$h : \mathcal{X} \to \mathcal{Y}$$

que transforma atributos medidos em uma classe prevista.

# Fluxo de um problema de classificação

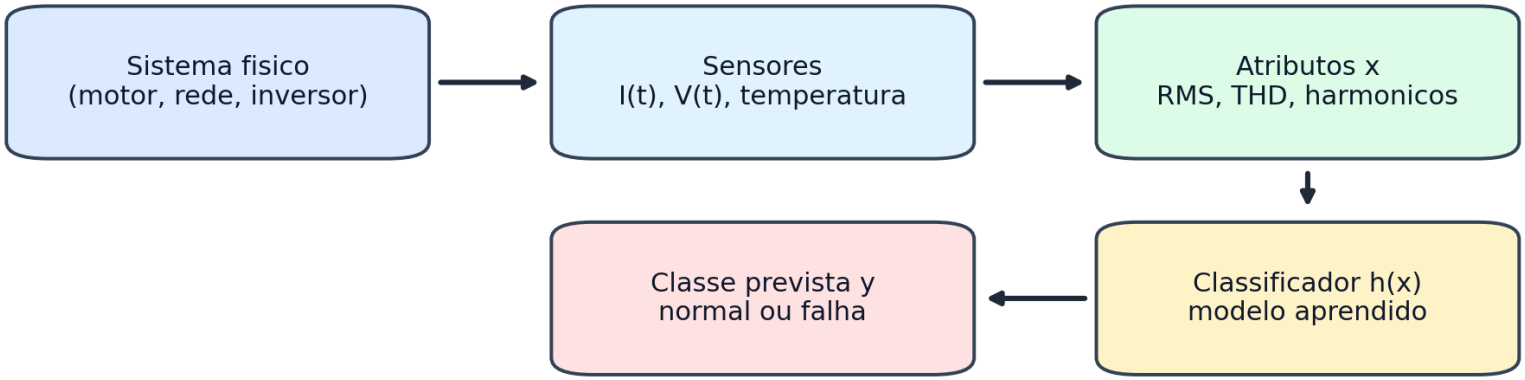


**Importante**

O classificador não acessa diretamente o sistema físico: ele recebe atributos extraídos ou calculados a partir das medições.

# Definição matemática mínima

## Dados rotulados

Um conjunto de treinamento contém pares:

$$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \ldots, (\mathbf{x}_n, y_n)$$

em que $\mathbf{x}_i$ é um vetor de atributos e $y_i \in \mathcal{Y}$ é uma classe conhecida.

Exemplo de atributos:

$$\mathbf{x}_i = \begin{bmatrix} I_{\text{RMS}} \\ V_{\text{RMS}} \\ \text{THD} \\ T_{\text{motor}} \end{bmatrix}$$

Exemplo de classes:

$$\mathcal{Y} = \{\text{normal}, \text{falha}\}$$

ou

$$\mathcal{Y} = \{0, 1, 2, \ldots, K-1\}.$$

# Classificação não é regressão

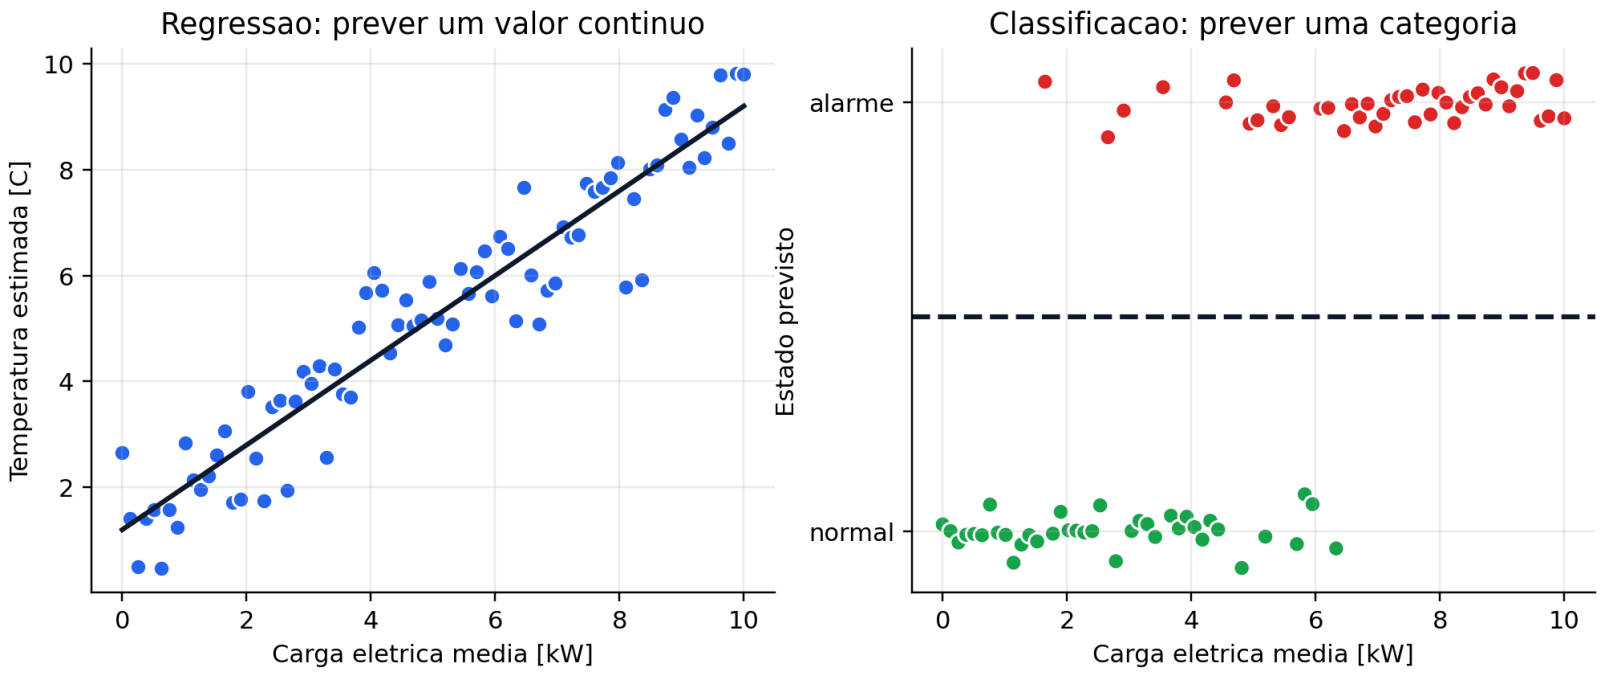


Em regressão, o alvo pode variar continuamente. Em classificação, a saída pertence a um conjunto discreto de rótulos.

# Binária, multiclasse e multirrótulo

**Binária**

Duas classes.

Ex.: normal/falha.

**Multiclasse**

Uma classe entre várias.

Ex.: tipo de falta elétrica.

**Multirrótulo**

Mais de uma classe pode ocorrer.

Ex.: falha mecânica e aquecimento.

**Cuidado**

A formulação do problema vem antes do algoritmo. O mesmo conjunto de medições pode gerar tarefas diferentes dependendo da pergunta feita.

# Atributos: a ponte entre Engenharia e ML

**Sinais brutos**

- corrente $i(t)$
- tensão $v(t)$
- vibração
- temperatura
- potência ativa/reativa

**Atributos calculados**

- RMS, pico, fator de crista
- THD e harmônicos
- energia em bandas de frequência
- média, variância e tendências
- indicadores de alarme

$\Rightarrow$ Um bom classificador depende tanto do algoritmo quanto da qualidade dos atributos.

# Fronteira de decisão

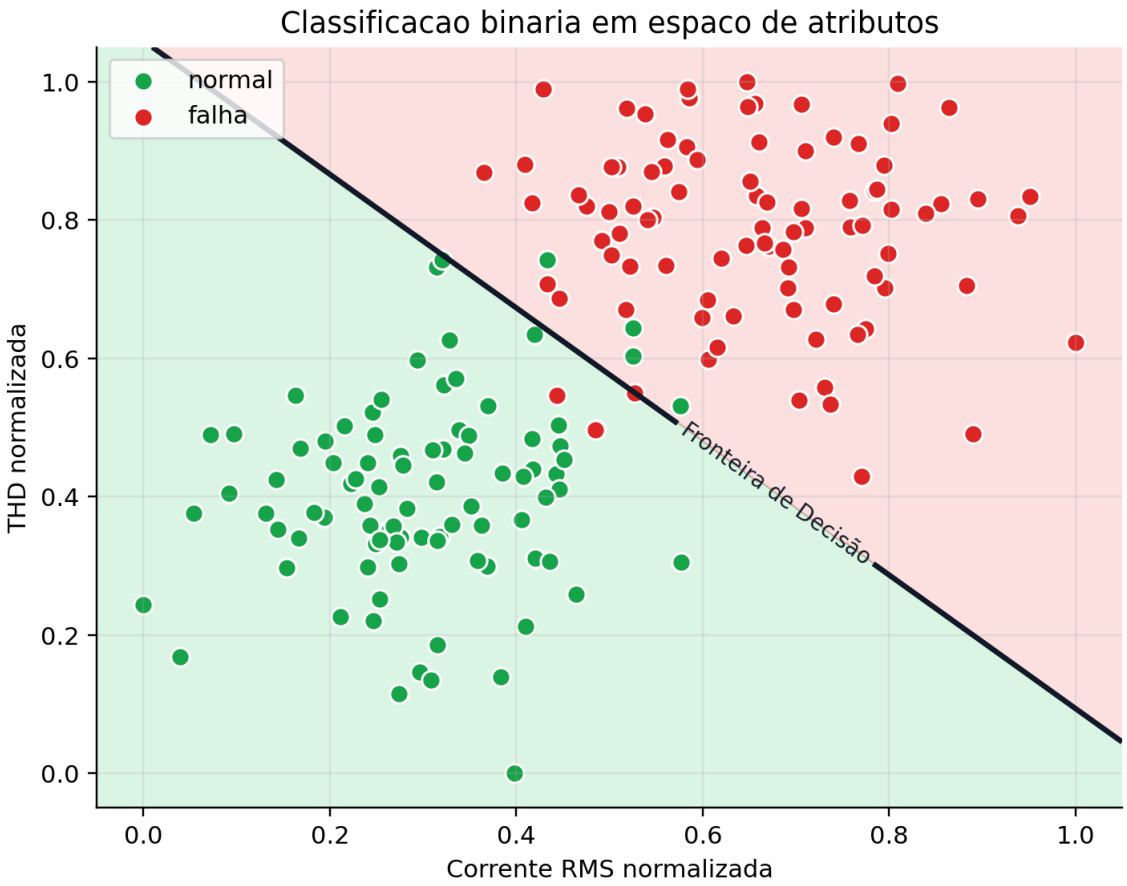


Cada ponto representa uma observação rotulada. A fronteira separa regiões onde o modelo prevê classes diferentes.

# Modelos diferentes, fronteiras diferentes

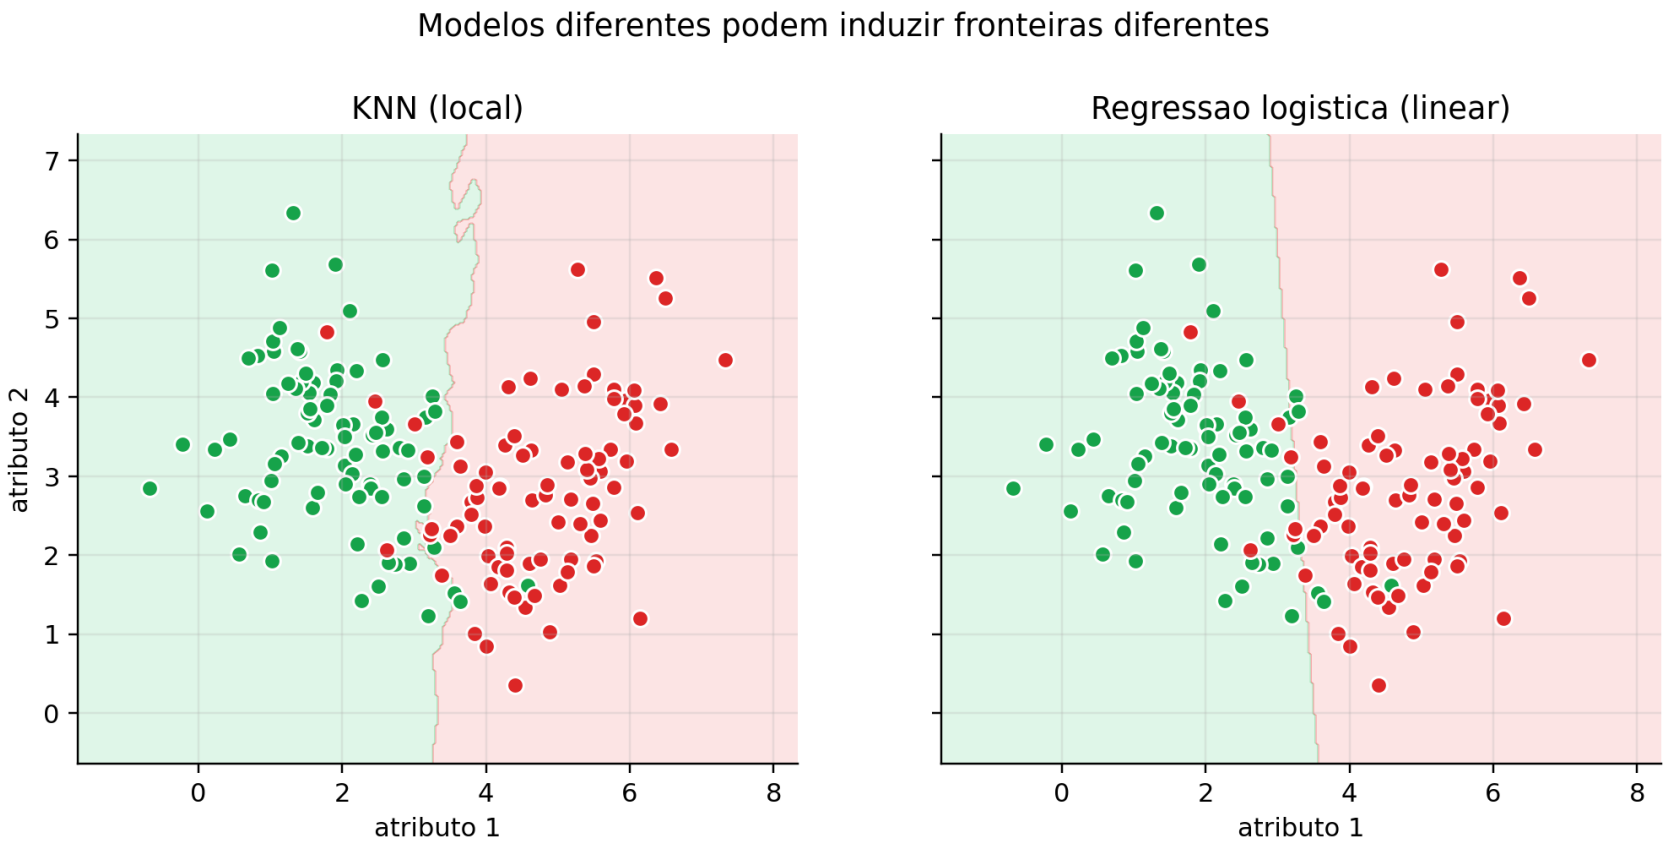


KNN aprende por vizinhança local; regressão logística induz uma separação linear no espaço transformado pelos atributos.

# Matriz de confusão

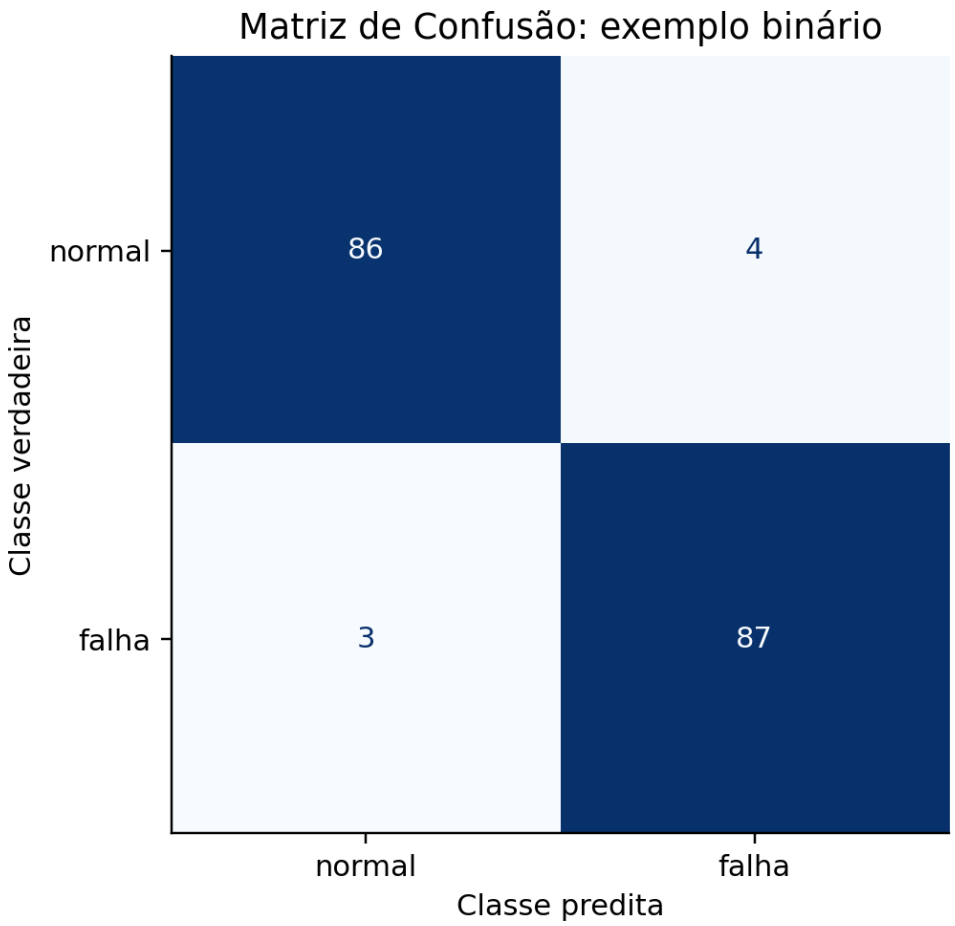


Para falhas críticas, um falso negativo pode ser mais grave que um falso positivo. A métrica deve refletir o custo do erro.

# Exemplo mínimo em Python

```python
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.30, random_state=1, stratify=y
)

modelo = LogisticRegression()
modelo.fit(X_train, y_train)

acuracia = modelo.score(X_test, y_test)
print(f"Acuracia no conjunto de teste: {acuracia:.3f}")
```

O padrão `fit`/`predict`/`score` será recorrente quando usarmos Scikit-Learn.

# Por que separar treino e teste?

O modelo funciona apenas nos exemplos históricos ou generaliza para medições futuras?

- **Treino**: usado para ajustar o modelo.
- **Teste**: usado para simular dados ainda não vistos.

**Risco**

item Avaliar no mesmo dado usado para treinar costuma produzir otimismo artificial.

# Intuição dos métodos que virão

| Método | Pergunta intuitiva |
|---|---|
| KNN | Quais exemplos históricos são mais parecidos com este novo caso? |
| Regressão logística | Qual é a probabilidade de pertencer à classe positiva? |
| SVM | Qual fronteira separa as classes com maior margem? |
| Árvores de decisão | Quais perguntas sequenciais separam melhor os casos? |
| Florestas aleatórias | Como combinar muitas árvores para reduzir instabilidade? |

# Referências


- GRUS, Joel. *Data Science do Zero: Noções Fundamentais com Python*. 2ª ed. Rio de Janeiro: Alta Books, 2020.
- MARTINS, S. A. M. Plano de ensino de Machine Learning aplicado à Engenharia. UFSJ, 2026.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.