Introdução às Técnicas de Regressão

Samir A. M. Martins

Universidade Federal de São João del-Rei
Departamento de Engenharia Elétrica
São João del-Rei, MG – Brasil

Graduação em Engenharia Elétrica

Ponto de partida

Alvo é numérico

Na regressão, o modelo não escolhe uma classe: ele estima um valor numérico.

- A pergunta deixa de ser "qual categoria?" e passa a ser "quanto?".
- O erro tem magnitude e unidade física.
- Dois modelos podem errar na mesma direção, mas com intensidades diferentes.
- Portanto, o centro da análise passa a ser o **resíduo**, dado por

$$e_i = y_i - \hat{y}_i$$

em que y_i é o valor real e $\hat{y}_i$ é o valor estimado pelo modelo.

Perguntas típicas de regressão

- Qual será a **demanda elétrica** nas próximas horas?
- Qual a **temperatura** esperada de um transformador sob determinada carga?
- Quanta **potência fotovoltaica** será gerada sob certa irradiância e temperatura?
- Qual é a **vida útil restante** estimada de um equipamento monitorado?

Essas perguntas exigem uma resposta em escala numérica, não uma decisão categórica.

Dados rotulados para regressão

Um conjunto de treinamento contém pares:

$$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \ldots, (\mathbf{x}_n, y_n)$$

em que $\mathbf{x}_i$ é um vetor de atributos/valores e $y_i \in \mathbb{R}$ é um valor numérico conhecido.

Exemplo de atributos:

$$\mathbf{x}_i = \begin{bmatrix} P_{\text{carga}} \\ I_{\text{RMS}} \\ T_{\text{amb}} \\ \text{THD} \end{bmatrix}$$

Exemplos de saídas:

$$y_i = T_{\text{motor}}$$

ou

$$y_i = \text{demanda futura.}$$

Alvo numérico

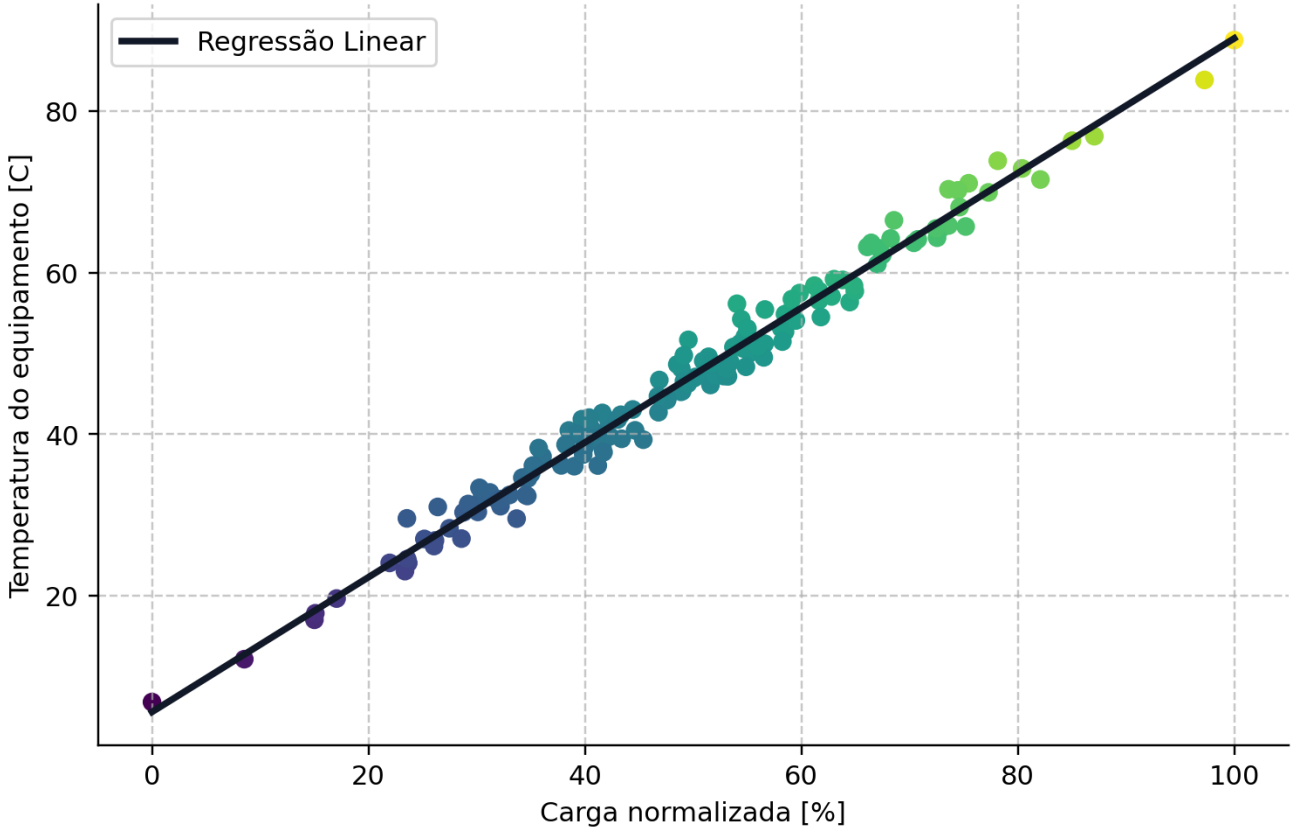

Cada ponto tem um valor numérico associado. A cor reforça que não há apenas duas ou três categorias: há uma escala contínua.

Análise de Resíduos

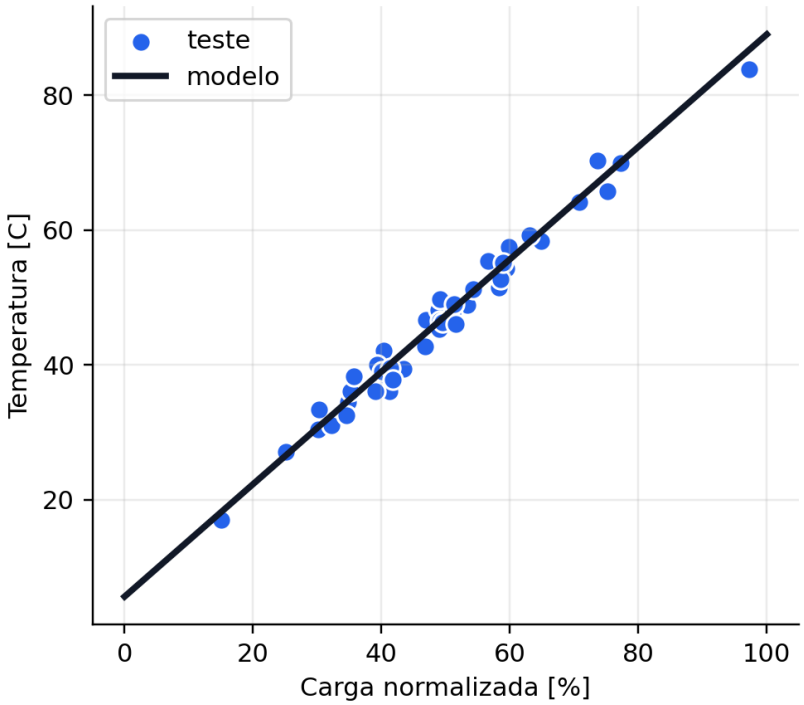

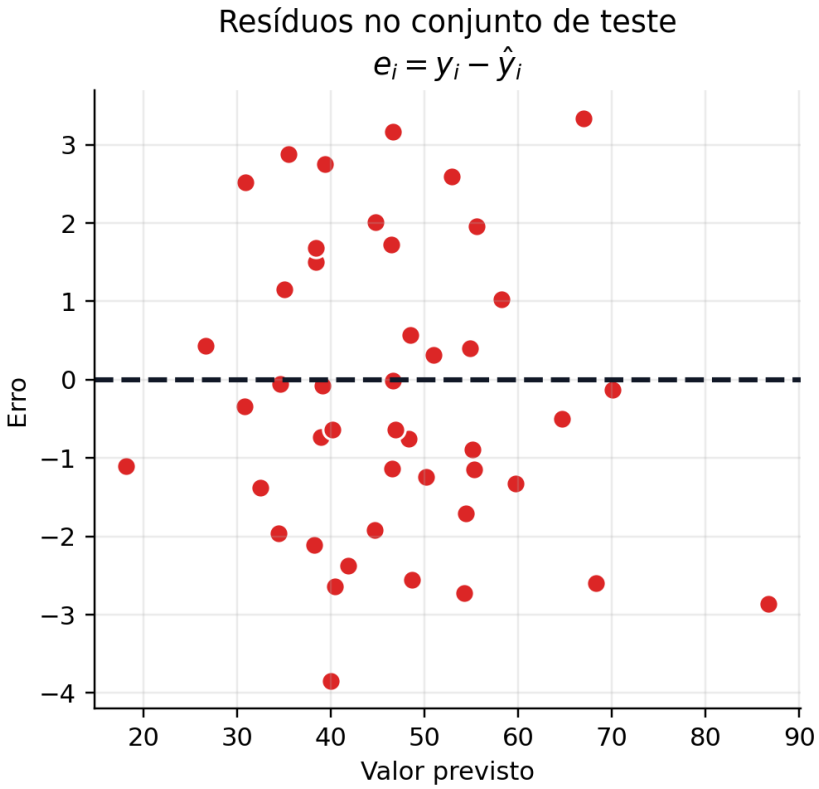

Resíduos grandes ou com padrão sistemático indicam que o modelo ainda não capturou parte importante do fenômeno.

Métricas básicas de regressão

Equações matemáticas

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

$$e_i = y_i - \hat{y}_i$$

em que y_i é o valor real, $\hat{y}_i$ é o valor previsto pelo modelo, $\bar{y}$ é a média dos valores reais e n é o número de observações.

Métricas básicas de regressão

Métrica	Interpretação
MAE	Erro absoluto médio. Mantém a mesma unidade da variável prevista.
RMSE	Penaliza mais fortemente erros grandes. Também fica na unidade da saída.
R^2	Mede a fração da variabilidade explicada pelo modelo. Quanto mais próximo de 1, melhor.
Resíduos	Diferenças entre valores reais e previstos. Ajudam a diagnosticar viés e padrões não modelados.

Modelos diferentes para saída numérica

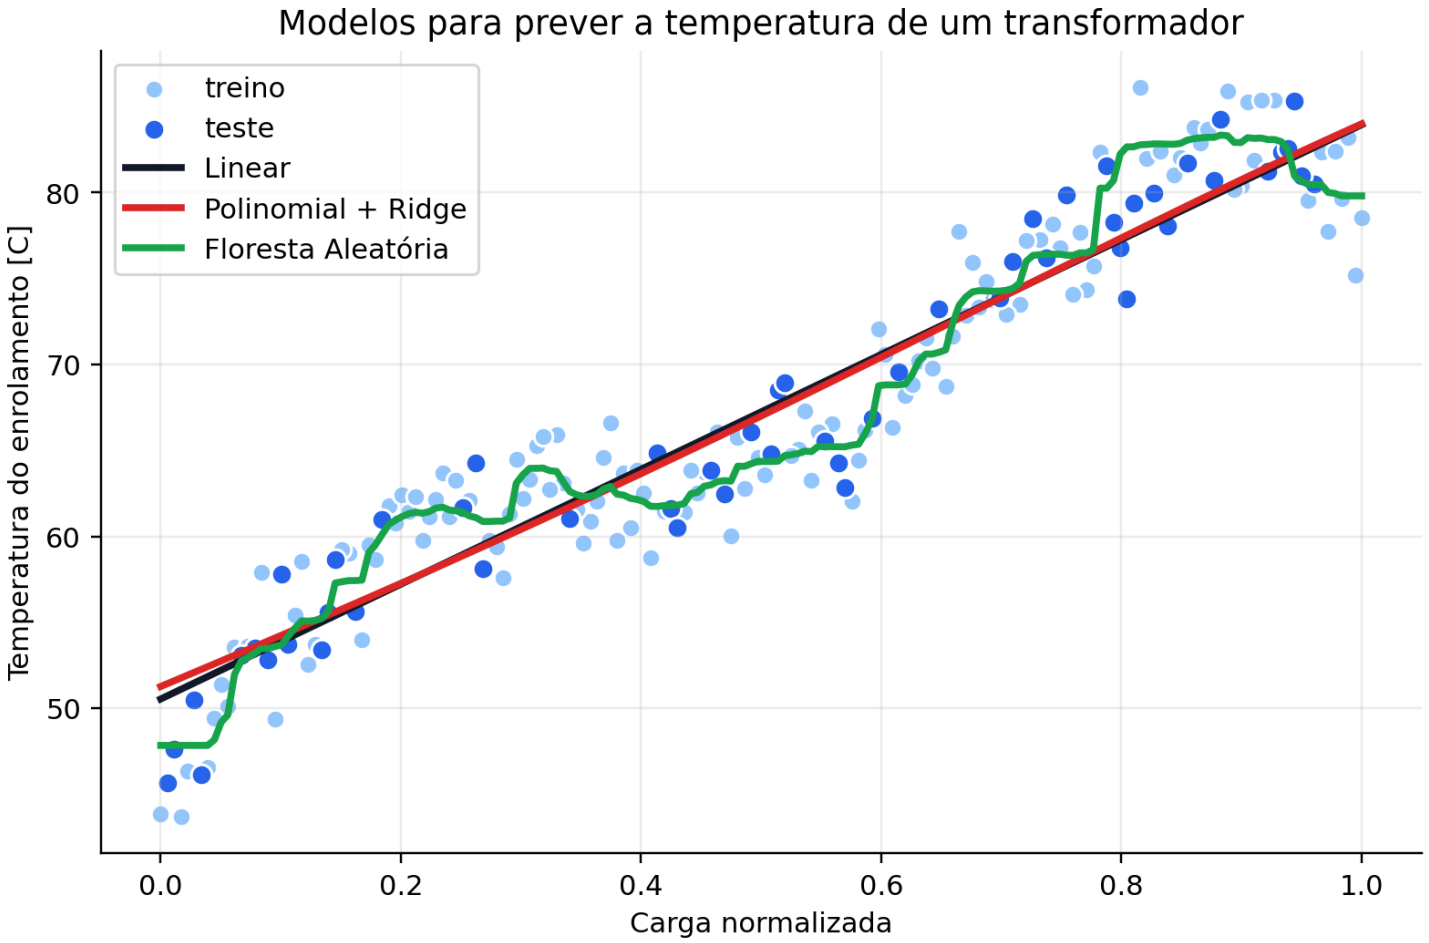

Um modelo linear pode ser insuficiente quando a relação física é curva, saturada ou dependente de regimes de operação.

Comparação por métricas

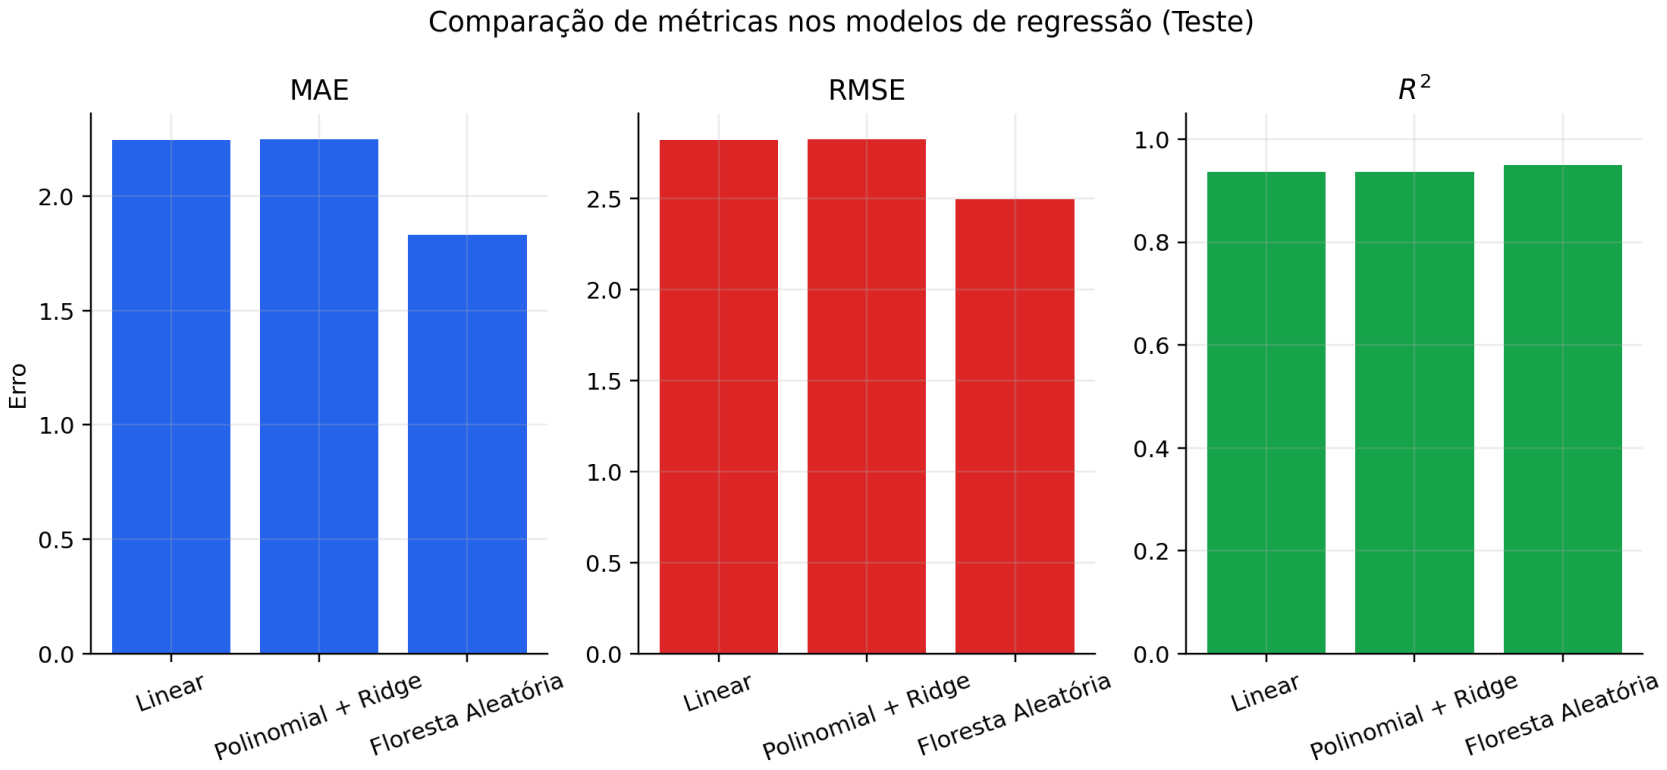

Exemplo mínimo em Python

```python
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error,
    root_mean_squared_error, r2_score

# Exemplo minimo especifico de regressao com sklearn.
modelo = LinearRegression()
modelo.fit(X_train, y_train)

y_pred = modelo.predict(X_test)

print(f"MAE: {mean_absolute_error(y_test, y_pred):.2f}")
print(f"RMSE: {root_mean_squared_error(y_test, y_pred):.2f}")
print(f"R2: {r2_score(y_test, y_pred):.3f}")
print("Primeiras previsoes:", np.round(y_pred[:8], 2))
```

O que virá neste capítulo

Tema	Pergunta intuitiva
Regressão linear	Qual relação linear aproxima melhor a saída contínua?
Modelos não lineares	Como capturar curvaturas, saturações e regimes de operação?
Scikit-Learn	Como treinar, avaliar e comparar regressores de forma padronizada?
SysIdentpy	Como construir modelos dinâmicos e não lineares para sistemas experimentais?

Referências

- GRUS, Joel. *Data Science do Zero: Noções Fundamentais com Python*. 2ª ed. Rio de Janeiro: Alta Books, 2020.
- MARTINS, S. A. M. Plano de ensino de Machine Learning aplicado à Engenharia. UFSJ, 2026.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.