Trabalho 1 (T1) — Gabarito de Exemplo

Análise de dados reais em engenharia elétrica: consumo e grandezas elétricas residenciais

Tema: monitoramento e análise de demanda elétrica a partir de medições reais
Base utilizada: *Individual Household Electric Power Consumption*
Fonte:
https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption

Referência da base

> Hebrail, G. e Berard, A. (2012). *Individual household electric power consumption* [Conjunto de dados]. repositório oficial UCI Machine Learning Repository. https://doi.org/10.24432/C58K54

Justificativa da escolha da base

- é uma **base real**, não simulada;
- está diretamente relacionada à engenharia elétrica;
- possui variáveis fisicamente interpretáveis;
- permite discutir estatística, probabilidade, qualidade de dados e possíveis tarefas de previsão de carga.

Limitações

- trata-se de apenas uma residência, então generalizações para redes maiores devem ser feitas com cautela;
- fatores externos importantes, como clima, ocupação e tarifa, não estão explicitamente presentes;
- parte dos dados contém valores ausentes, exigindo estratégia de tratamento.

Integrantes do grupo

- Aluno 1 — substituir pelo nome real
- Aluno 2 — substituir pelo nome real
- Aluno 3 — substituir pelo nome real

Repositório do grupo

- Inserir aqui o link do GitHub

Convenção de cores para identificar contribuições

- Azul: Aluno 1

- Verde: Aluno 2
- Vermelho: Aluno 3

---

1. Definição do problema

Em engenharia elétrica, o monitoramento de potência, tensão, corrente e consumo por circuitos é fundamental para:

- análise de carga;
- identificação de padrões de uso;
- planejamento energético;
- avaliação de eficiência;
- formulação de problemas de previsão e detecção de eventos.

Nesta base, temos medições reais de uma residência na região de Paris, com resolução de **1 minuto**, entre dezembro de 2006 e novembro de 2010. As variáveis incluem potência ativa global, potência reativa global, tensão, intensidade de corrente e três submedições de energia.

A pergunta principal deste estudo é:

> **Quais padrões estatísticos e temporais explicam o comportamento do consumo elétrico e das grandezas elétricas medidas ao longo do tempo?**

Objetivos específicos:

- descrever a base e avaliar sua consistência;
- tratar valores ausentes de forma tecnicamente justificável;
- construir variáveis derivadas com interpretação elétrica;
- investigar distribuições, sazonalidade e relações entre variáveis;
- discutir dependência, independência, correlação e limitações causais;
- propor como a base pode ser usada em um problema futuro de aprendizado de máquina.

Out[1]:

	Global_active_power	Global_reactive_power	Voltage	Global_intensity	Sub_metering_
0	4.2160	0.4180	234.8400	18.4000	0.000
1	5.3600	0.4360	233.6300	23.0000	0.000
2	5.3740	0.4980	233.2900	23.0000	0.000
3	5.3880	0.5020	233.7400	23.0000	0.000
4	3.6660	0.5280	235.6800	15.8000	0.000

2. Leitura e organização da base em Python

O processamento inicial consiste em:

- leitura do arquivo de texto;
- Intepretação de "?" como valor ausente;
- combinação de "Date" e "Time" em uma coluna temporal única;
- ordenação cronológica.

	variavel	unidade	descricao
0	Global_active_power	kW	Potência ativa média global por minuto
1	Global_reactive_power	kW	Potência reativa média global por minuto
2	Voltage	V	Tensão média por minuto
3	Global_intensity	A	Corrente média global por minuto
4	Sub_metering_1	Wh	Energia do subcircuito 1 por minuto
5	Sub_metering_2	Wh	Energia do subcircuito 2 por minuto
6	Sub_metering_3	Wh	Energia do subcircuito 3 por minuto
7	timestamp	datetime	Instante da medição

Out[7]:

	count	mean	min	25%	50%
Global_active_power	2,049,280.0000	1.0916	0.0760	0.3080	0.6020
Global_reactive_power	2,049,280.0000	0.1237	0.0000	0.0480	0.1000
Voltage	2,049,280.0000	240.8399	223.2000	238.9900	241.0100
Global_intensity	2,049,280.0000	4.6278	0.2000	1.4000	2.6000
Sub_metering_1	2,049,280.0000	1.1219	0.0000	0.0000	0.0000
Sub_metering_2	2,049,280.0000	1.2985	0.0000	0.0000	0.0000
Sub_metering_3	2,049,280.0000	6.4584	0.0000	0.0000	1.0000
timestamp	2075259	2008-12-06 07:12:59.999994112	2006-12-16 17:24:00	2007-12-12 00:18:30	2008-12-06 07:13:00

3. Tratamento e preparação dos dados

Decisão sobre valores ausentes

Como a base é uma série temporal regular de 1 minuto, a interpolação no tempo foi feita. Neste dataset, o percentual de faltantes é baixo;

	missing_values	missing_pct	dtype
Global_active_power	25979	1.2518	float64
Global_reactive_power	25979	1.2518	float64
Voltage	25979	1.2518	float64
Global_intensity	25979	1.2518	float64
Sub_metering_1	25979	1.2518	float64
Sub_metering_2	25979	1.2518	float64
Sub_metering_3	25979	1.2518	float64
timestamp	0	0.0000	datetime64[ns]

```
Linhas totais: 2075259
Duplicatas exatas: 0
Timestamps duplicados: 0
Intervalo temporal: 2006-12-16 17:24:00 até 2010-11-26 21:02:00
```

Out[12]:

timestamp	Global_active_power	Global_reactive_power	Voltage	Global_intensity	Sub_
2006-12-16 17:00:00	4.2229	0.2290	234.6439	18.1000	
2006-12-16 18:00:00	3.6322	0.0800	234.5802	15.6000	
2006-12-16 19:00:00	3.4002	0.0852	233.2325	14.5033	
2006-12-16 20:00:00	3.2686	0.0751	234.0715	13.9167	
2006-12-16 21:00:00	3.0565	0.0767	237.1587	13.0467	

Comentários sobre a preparação realizada

- Os valores ausentes estão concentrados nas variáveis elétricas, mas em proporção baixa frente ao total da base.
- Foram criadas variáveis derivadas importantes:
  - `energy_active_wh` : energia ativa aproximada por minuto;
  - `sub_metering_total_wh` : soma das submedições;
  - `unmetered_energy_wh` : consumo não diretamente coberto pelas três submedições;
  - `high_load` : evento de alta carga, útil para probabilidade condicional e uma formulação classificatória;
  - agregações horárias e diárias, úteis para análise temporal e para tarefas futuras de previsão.

4. Estatística descritiva

Primeiro analisamos a base em resolução de minuto. Em seguida, usamos a série diária para descrever tendência de longo prazo com menor ruído.

	mean	median	std	min	max
Global_active_power	1.0903	0.6140	1.0526	0.0760	11.1220
Global_reactive_power	0.1236	0.1000	0.1124	0.0000	1.3900
Voltage	240.8328	241.0000	3.2378	223.2000	254.1500
Global_intensity	4.6215	2.7516	4.4244	0.2000	48.4000
energy_active_wh	18.1713	10.2333	17.5438	1.2667	185.3667
sub_metering_total_wh	8.8411	1.0000	12.8079	0.0000	134.0000
unmetered_energy_wh	9.3302	5.5333	9.5465	-2.4000	124.8333

	skewness
Global_active_power	1.7916
Global_reactive_power	1.2630
Voltage	-0.3249
Global_intensity	1.8553
energy_active_wh	1.7916
sub_metering_total_wh	2.2379
unmetered_energy_wh	2.4862

Out[13]:

	count	mean	std	min	25%	
Global_active_power	1,442.0000	1.0913	0.4211	0.1738	0.8112	1
Voltage	1,442.0000	240.8304	2.0500	231.0882	240.0684	240
Global_intensity	1,442.0000	4.6258	1.7437	0.8083	3.5008	4
energy_active_wh	1,442.0000	26,151.3225	10,031.3262	4,171.6333	19,468.3500	25,822

Interpretação da estatística descritiva

- A potência ativa global tem distribuição assimétrica à direita, indicando muitos instantes de baixa carga e menos instantes de carga elevada.
- A tensão possui variabilidade bem menor do que potência e corrente, o que é coerente com um sistema alimentado em faixa relativamente estável.
- A corrente acompanha a potência ativa com forte associação física esperada.
- A variável `unmetered_energy_wh` é útil porque representa o consumo não diretamente associado às três submedições informadas.

5. Avaliacao de distribuicoes e teste de normalidade

Para fortalecer a parte estatistica, nao basta dizer que a distribuicao "parece assimetrica". Vamos verificar formalmente:

- o grau de assimetria das principais variaveis;
- se uma hipotese de normalidade e plausivel;
- se distribuicoes alternativas, representam melhor variaveis estritamente positivas.

Esse passo e importante porque varios metodos estatisticos e de aprendizado de maquina assumem, explicitamente ou nao, comportamentos aproximadamente gaussianos. Em dados reais de consumo eletrico, essa hipotese costuma falhar para potencia e corrente, enquanto a tensao tende a ficar mais proxima de uma distribuicao concentrada e menos assimetrica.

	variavel	media	mediana	desvio_padrao	assimetria	curtose_excesso
0	Global_active_power	1.0903	0.6140	1.0526	1.7916	4.2679
1	Global_reactive_power	0.1236	0.1000	0.1124	1.2630	2.6181
3	Global_intensity	4.6215	2.7516	4.4244	1.8553	4.6566
4	energy_active_wh	18.1713	10.2333	17.5438	1.7916	4.2679
5	unmetered_energy_wh	9.3302	5.5333	9.5465	2.4862	7.9475
2	Voltage	240.8328	241.0000	3.2378	-0.3249	0.7108

	variavel	distribuicao	AIC	KS_stat	KS_pvalor
0	Global_active_power	lognormal	41,283.1892	0.1288	0.0000
1	Global_active_power	gamma	42,933.9391	0.1490	0.0000
2	Global_active_power	weibull_min	43,243.0712	0.1380	0.0000
3	Global_active_power	normal	58,430.5313	0.1806	0.0000
4	Global_intensity	lognormal	99,135.6992	0.1266	0.0000
5	Global_intensity	gamma	100,541.0394	0.1461	0.0000
6	Global_intensity	weibull_min	100,888.1942	0.1356	0.0000
7	Global_intensity	normal	115,845.1482	0.1800	0.0000
8	unmetered_energy_wh	lognormal	123,577.4747	0.0957	0.0000
9	unmetered_energy_wh	gamma	127,570.2392	0.1540	0.0000
10	unmetered_energy_wh	weibull_min	128,709.6620	0.1425	0.0000
11	unmetered_energy_wh	normal	147,600.9176	0.2305	0.0000

	variavel	distribuicao	melhor_AIC	melhor_KS_stat	melhor_KS_pvalor
0	Global_active_power	lognormal	41,283.1892	0.1288	0.0000
1	Global_intensity	lognormal	99,135.6992	0.1266	0.0000
2	unmetered_energy_wh	lognormal	123,577.4747	0.0957	0.0000

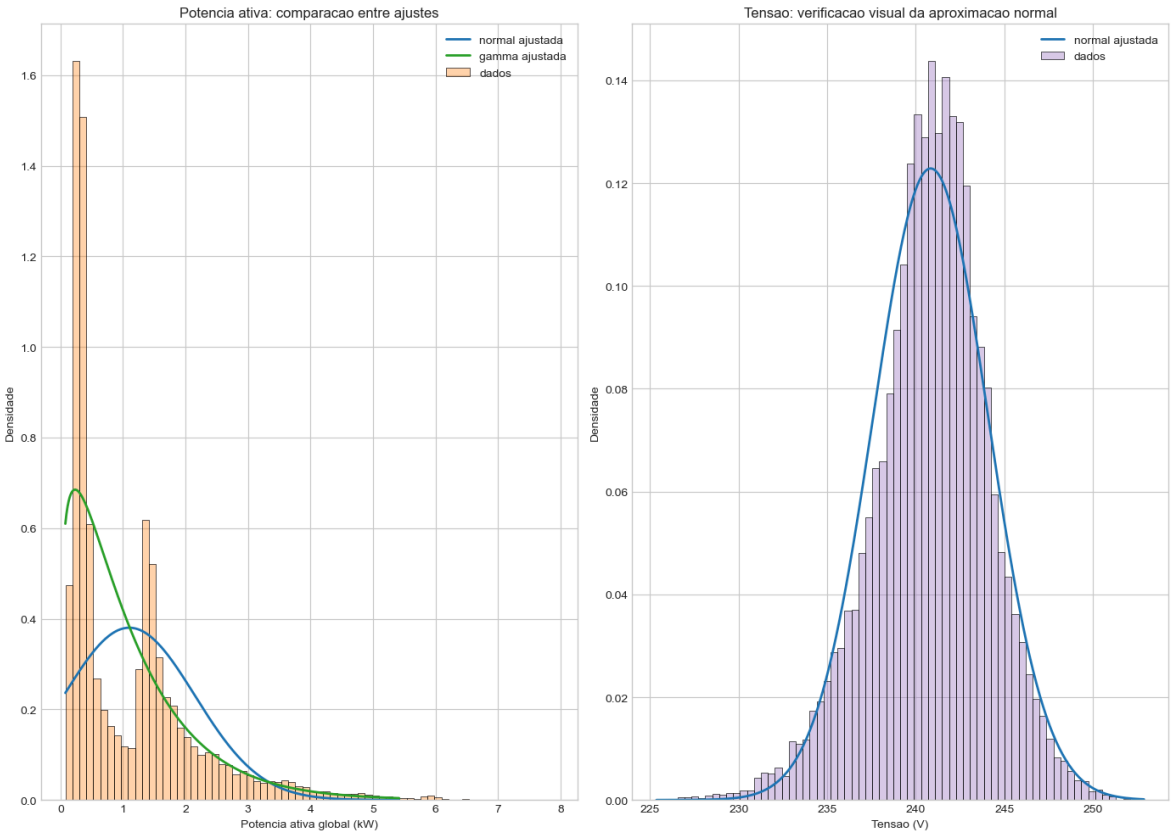

Interpretação

- **Potência ativa** não se ajusta bem à normal.
- Ela é **assimétrica**, então a **gamma** parece descrever melhor os dados.
- `Voltage` fica mais próxima de uma **normal**.
- Assim, **cada variável pode exigir uma distribuição diferente**.

6. Visualizações e interpretações

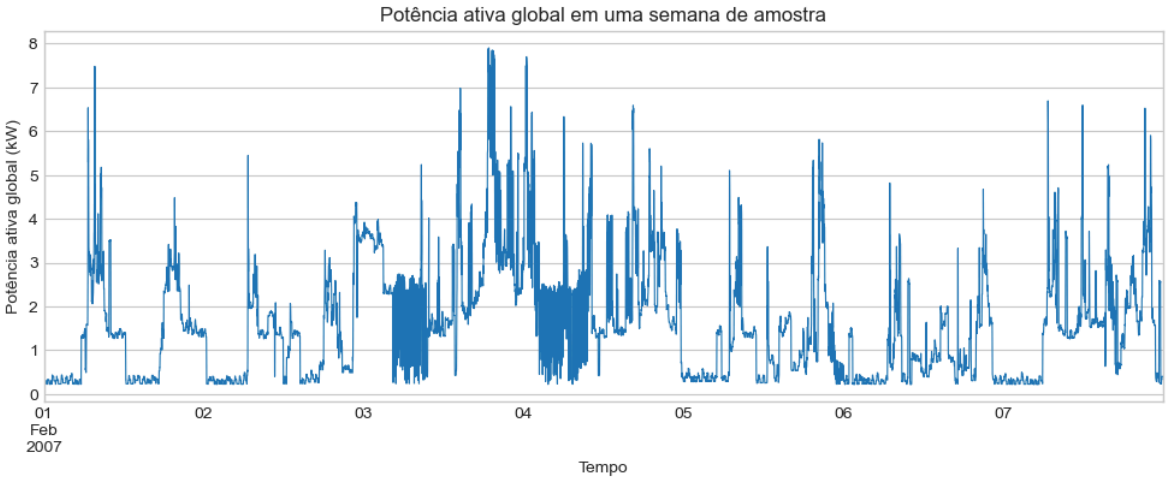

Análise do gráfico 1. A série de uma semana evidencia o caráter fortemente variável da carga elétrica, com ciclos diários claros e picos localizados. Isso é típico de consumo residencial, em que hábitos humanos e uso de equipamentos moldam o perfil temporal.

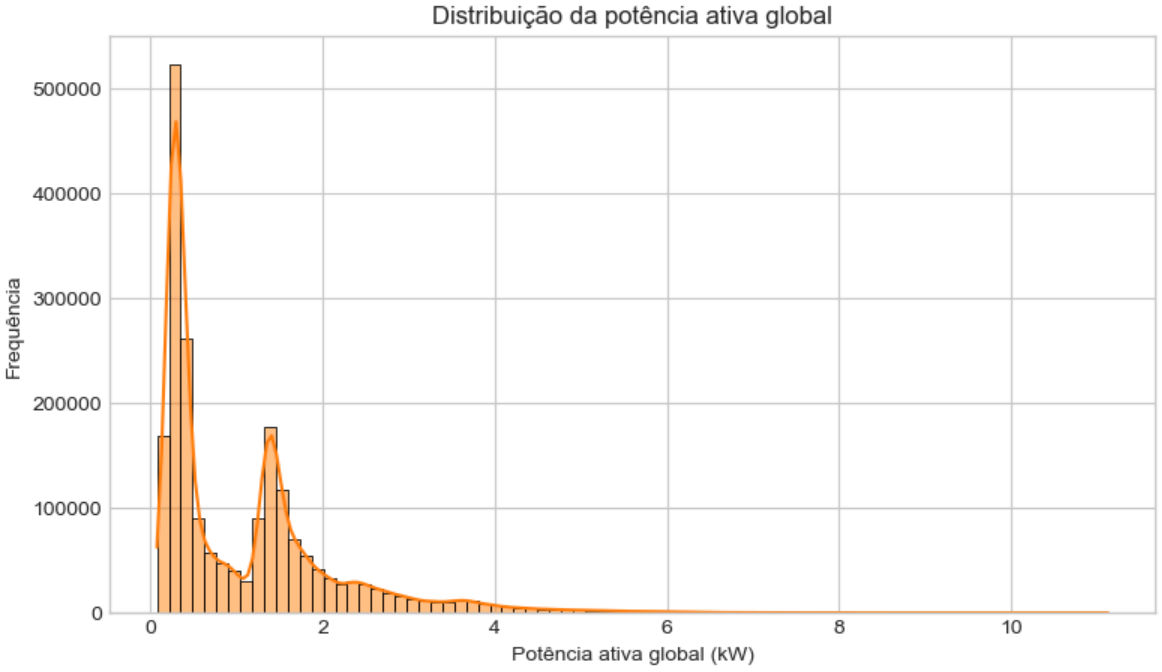

Análise do gráfico 2. A distribuição é fortemente concentrada em cargas baixas a moderadas, com cauda à direita. Isso sugere que o estado usual da instalação é de consumo moderado, enquanto picos altos ocorrem em menor frequência.

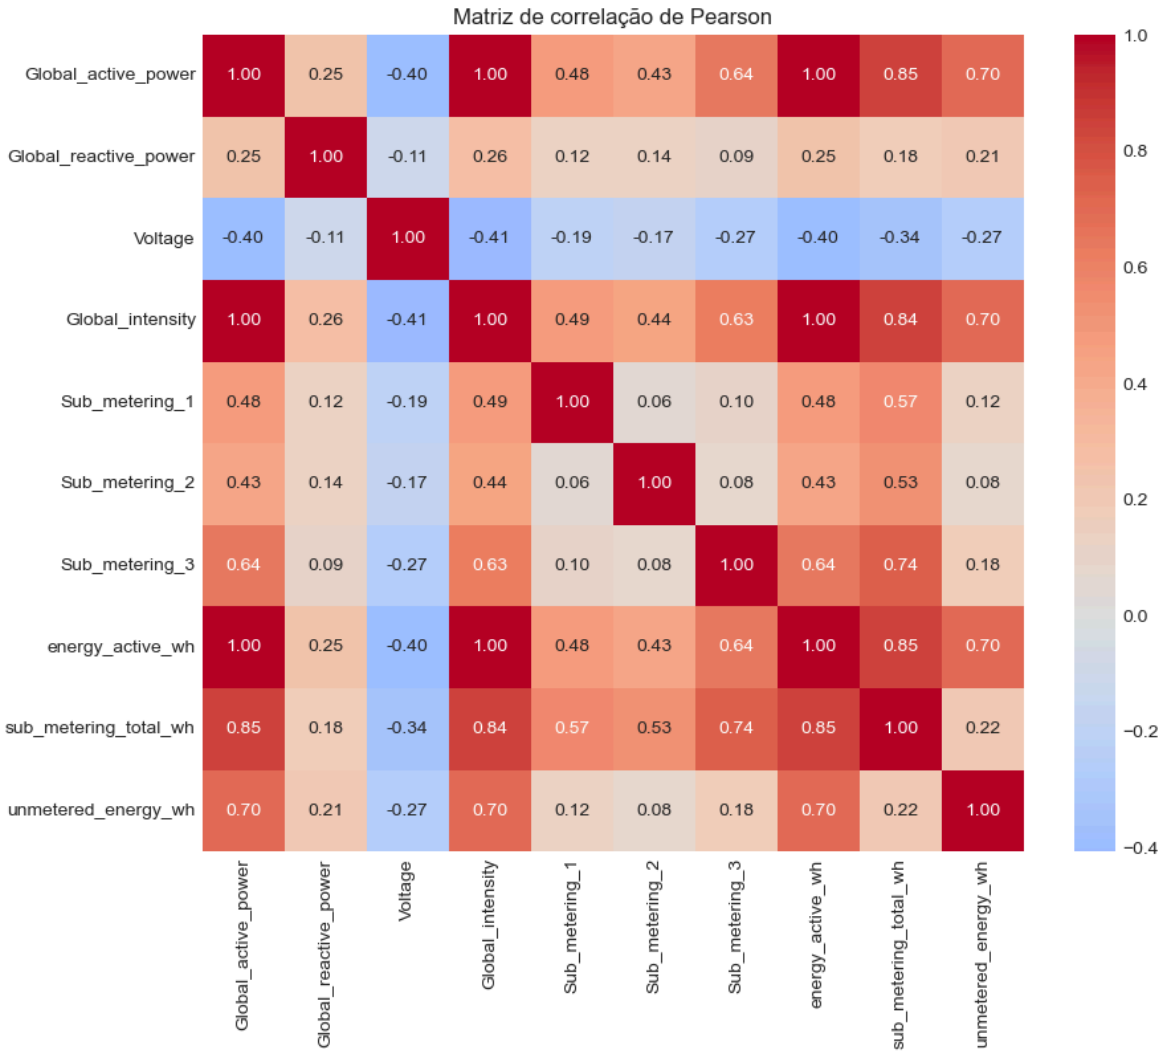

Análise do gráfico 3. Potência ativa e corrente apresentam correlação alta, o que é coerente com as relações elétricas fundamentais. Tensão, por outro lado, tende a variar menos e a se relacionar de forma diferente com a carga, podendo até mostrar associação negativa em certos regimes, sem que isso implique causalidade direta isolada.

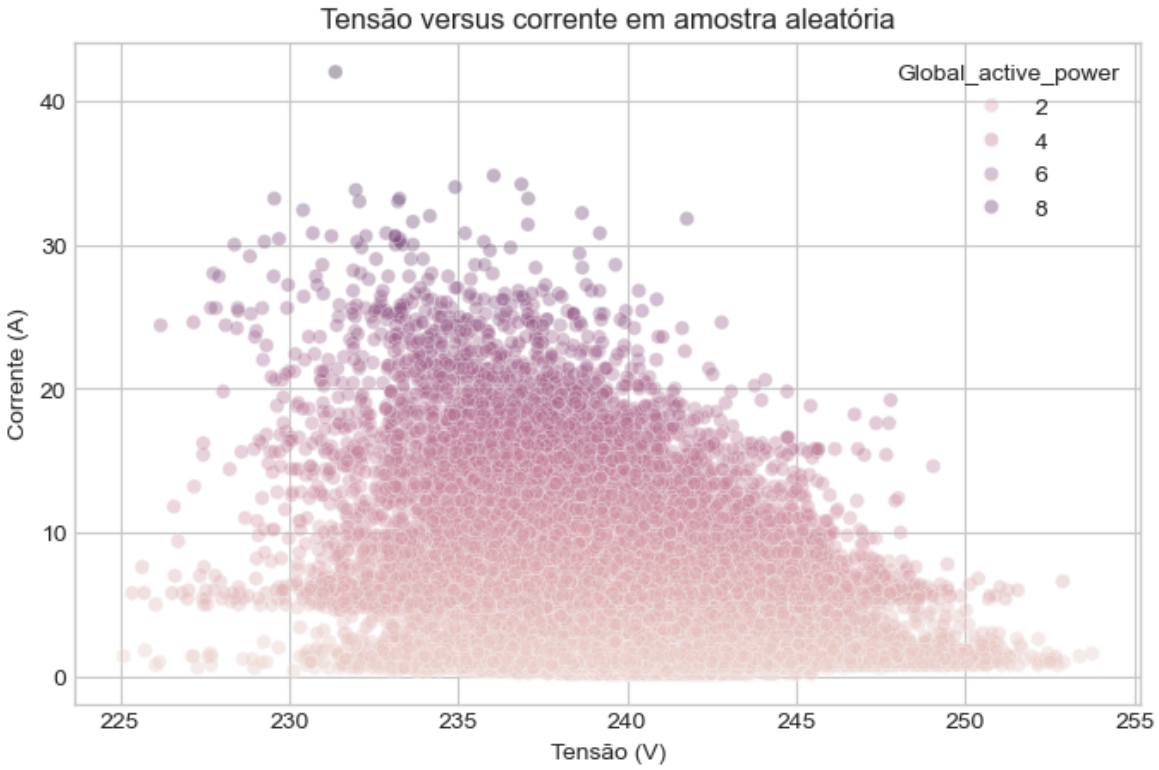

Análise do gráfico 4. A nuvem de pontos mostra que correntes maiores tendem a ocorrer em níveis mais altos de potência ativa. A tensão ocupa uma faixa relativamente estreita, o que reforça a leitura de que o sistema é mais sensível a variações de carga do que a grandes oscilações de tensão.

Análise do gráfico 5. O perfil médio diário evidencia aumento de consumo no período da noite, compatível com maior ocupação residencial e acionamento simultâneo de equipamentos. Esse comportamento é importante para estudos de demanda e planejamento de carga.

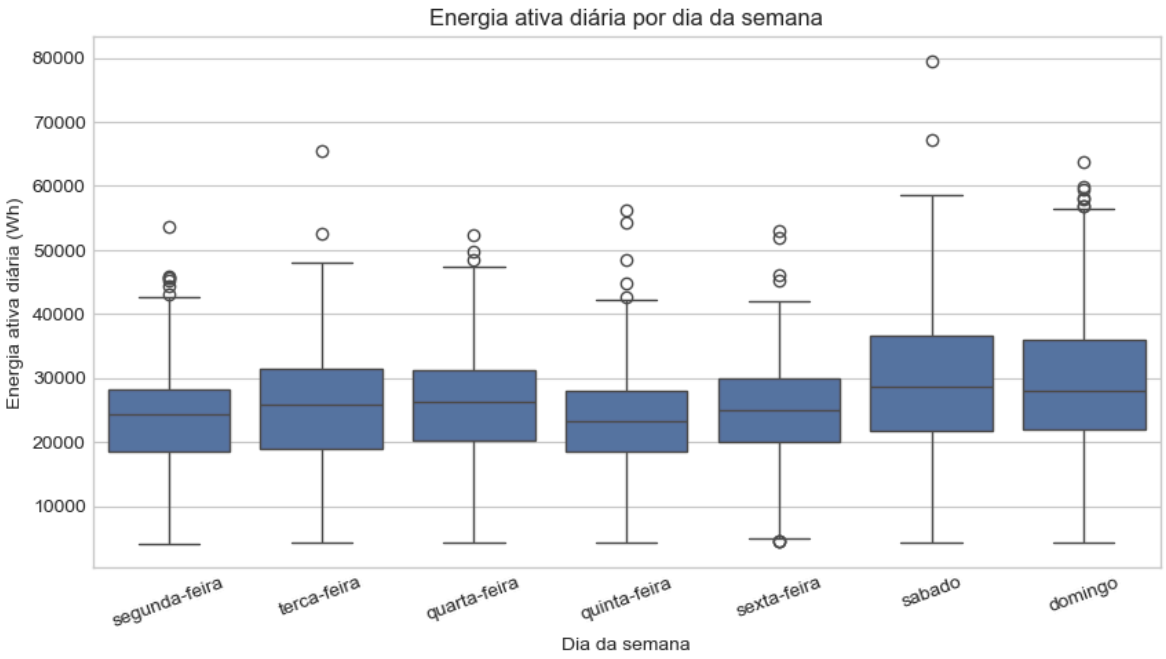

Análise do gráfico 6. Os boxplots mostram a dispersão do consumo diário ao longo da semana. Mesmo quando as medianas são próximas, a amplitude interquartil revela que o padrão de uso não é rígido e sofre influência de hábitos e eventos cotidianos.

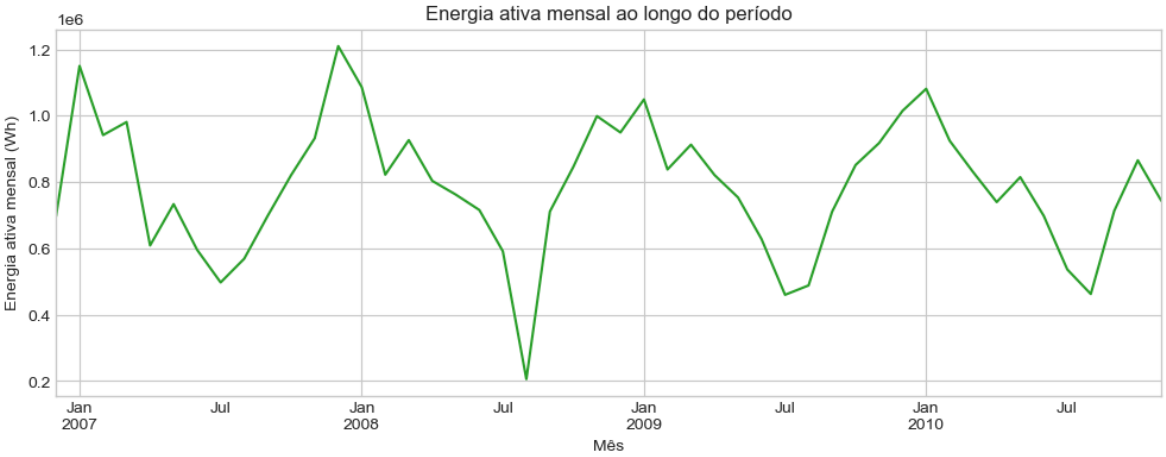

Análise do gráfico 7. A energia mensal apresenta sazonalidade e flutuações de longo prazo. Em bases elétricas reais, esse tipo de comportamento pode estar associado a clima, ocupação, férias, eletrodomésticos e outras variáveis externas não observadas diretamente na base.

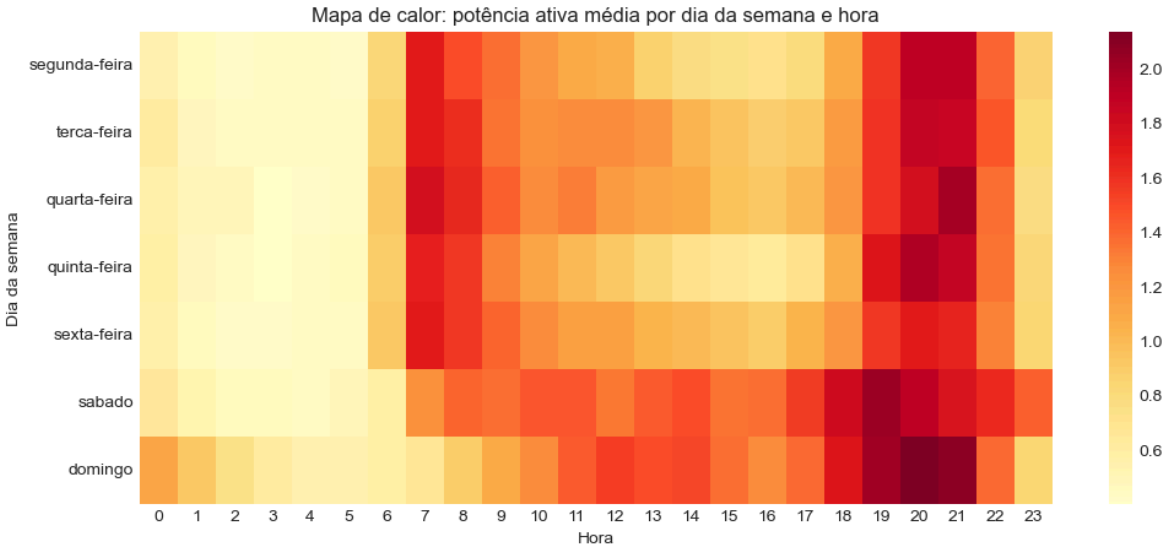

Análise do gráfico 8. O mapa de calor sintetiza o perfil de carga semanal. Ele permite identificar rapidamente janelas horárias de maior demanda e comparar dias úteis e fins de semana, algo muito útil em aplicações de previsão de carga e gestão de energia.

7. Correlação, causalidade e correlações espúrias

Algumas correlações desta base são fisicamente plausíveis:

- corrente com potência ativa;
- submedições com energia total;
- componentes temporais com regime de carga.

Mas o cuidado metodológico continua necessário:

- correlação entre mês e consumo não prova efeito climático, porque clima não está na base;
- associação entre tensão e corrente pode refletir comportamento do sistema sob carga, não uma relação causal unidirecional simples;
- correlação entre submedições e carga total é parcialmente estrutural, pois as variáveis fazem parte do mesmo balanço energético.

Isso é importante para evitar conclusões apressadas e para mostrar maturidade técnica na análise.

Out[33]:

	Pearson
energy_active_wh	1.0000
Global_active_power	1.0000
Global_intensity	0.9989
sub_metering_total_wh	0.8471
unmetered_energy_wh	0.7012
Sub_metering_3	0.6393
Sub_metering_1	0.4838
Sub_metering_2	0.4339
hour	0.2798
Global_reactive_power	0.2450
year	-0.0324
month	-0.0331
Voltage	-0.3955

Pearson permite verificar se a associação é predominantemente linear. Em bases elétricas reais, esse cuidado é útil porque nem toda relação técnica é linear ao longo de toda a faixa operacional.

8. Fechamento conceitual ligado a aprendizado de máquina

Esta base pode ser usada em mais de uma formulação de aprendizado de máquina:

- **regressão**: prever `Global_active_power` em instantes futuros ou a partir de outras grandezas;
- **classificação**: prever ocorrência de `high_load`;
- **séries temporais**: previsão de carga horária, diária ou semanal;
- **detecção de anomalias**: identificar padrões elétricos atípicos.

Formulação possível para T2

Uma formulação bastante coerente seria prever a **potência ativa média horária** ou a **energia diária**, o que caracteriza um problema de regressão com forte componente temporal.

Desafios esperados

- dependência temporal entre observações;
- sazonalidade diária, semanal e mensal;
- necessidade de evitar vazamento temporal no particionamento;

- presença de ruído operacional;
- possíveis relações não lineares entre variáveis.

9. Conclusão

Este notebook apresentou uma solução possível para o T1 usando **dados reais de engenharia elétrica**.

Síntese dos principais resultados

- a base possui forte estrutura temporal e comportamento típico de carga residencial;
- potência ativa e corrente apresentam associação elevada, coerente com a física do problema;
- existe padrão claro de pico em determinados horários;
- eventos de alta carga são estatisticamente dependentes do período noturno;
- a base é adequada para formulações futuras de regressão, classificação e previsão temporal.

O que um bom grupo deve demonstrar ao entregar seu T1

- domínio da leitura e organização dos dados;
- tratamento explícito e justificado dos problemas encontrados;
- estatística descritiva **com interpretação**, não apenas tabelas;
- gráficos úteis, **claros e comentados**;
- maturidade conceitual ao distinguir correlação de causalidade;
- fechamento coerente com uma futura etapa de aprendizado de máquina.